

Байесовское мультимоделирование: распределения и их свойства

Московский Физико-Технический Институт

2021

Что такое случайная величина

Заданы:

- Множество элементарных событий Ω
- Сигма-алгебра \mathfrak{F} на множестве Ω
- Система $\mathfrak{B}(\mathbb{R})$ борелевских множеств на \mathbb{R}

Действительная функция $w(\omega) : \Omega \rightarrow \mathbb{R}$ называется случайной величиной, если для любого $B \in \mathfrak{B}(\mathbb{R})$:

$$\{\omega : w(\omega) \in B\} \in \mathfrak{F}.$$

Описание случайных величин

Дискретная случайная величина w принимает счётное множество значений $A = \{a_1, a_2, \dots\}$ с вероятностями p_1, p_2, \dots , $\sum_i p_i = 1$.

$f(a_i) = p(w = a_i) = p_i$ — **функция вероятности**.

Непрерывная случайная величина задаётся с помощью **функции распределения**:

$$F_w(t) = p(w \leq t)$$

или **плотности распределения**:

$$f(w) : \int_a^b f(w) dw = p(a \leq w \leq b).$$

Метод максимума правдоподобия

$$\mathbf{X} \sim f(\mathbf{x}, w),$$

$$L(\mathbf{X}, w) = \prod_{x \in \mathbf{X}} f(x, w),$$

$$\hat{w} \equiv \arg \max_w L(\mathbf{X}, w).$$

Удобно прологарифмировать:

$$\log L(\mathbf{X}, w) = \sum_{x \in \mathbf{X}} \log f(x, w),$$

$$\hat{w} \equiv \arg \max_w \log L(\mathbf{X}, w).$$

Производные функции правдоподобия

Score function:

$$S(w) \equiv \frac{\partial}{\partial w} \log L(w)$$

ОМП — решение score equation:

$$S(w) = 0$$

Информация Фишера:

$$I(w) \equiv -\frac{\partial^2}{\partial w^2} \log L(w)$$

Дисперсия ОМП:

$$\mathbb{D}\hat{\theta} \approx I^{-1}(\hat{w})$$

Свойства ОМП

- состоятельность:

$$\hat{w}_n \xrightarrow{P} w$$

- асимптотическая нормальность: при $n \rightarrow \infty$

$$\hat{w} \sim \mathcal{N}(w, I^{-1}(w))$$

- эффективность: ОМП имеют наименьшую дисперсию среди всех состоятельных оценок
- инвариантность: $g(\hat{w})$ — ОМП-оценка для $g(w)$

Максимизация правдоподобия

Максимизация правдоподобия эквивалентна минимизации дивергенции между целевым и истинным распределением:

$$\max_w L(\mathbf{X}, w) \iff \min KL(p^*(\mathbf{X}) | p(\mathbf{X}|w)).$$

Идея доказательства

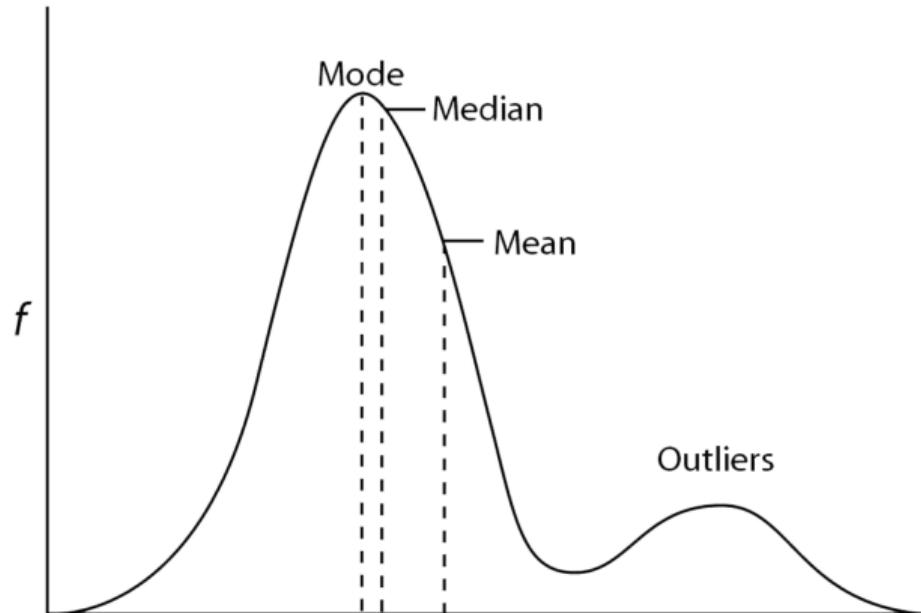
$$\begin{aligned}KL(p^*(\mathbf{X}) | p(\mathbf{X}|w)) &= E_{x \sim p^*(\mathbf{X})} \log \left(\frac{p^*(\mathbf{X})}{p(\mathbf{X}|w)} \right) = \\&= \text{Const} - E_{x \sim p^*(\mathbf{X})} \log p(\mathbf{X}|w) \approx^{3БЧ} \\&\approx \text{Const} - L(\mathbf{X}, w).\end{aligned}$$

Оценки центральной тенденции

Выборочное среднее — среднее арифметическое по выборке.

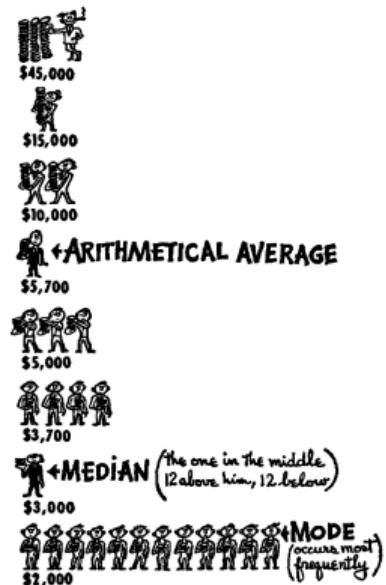
Выборочная медиана — центральный элемент вариационного ряда.

Выборочная мода — самое распространённое значение в выборке.



Оценки центральной тенденции

(Huff, 1954):



Медиана

- **квантиль порядка** $\alpha \in (0, 1)$:

$$w_\alpha: p(w \leq w_\alpha) \geq \alpha, \quad p(w \geq w_\alpha) \geq 1 - \alpha$$

эквивалентное определение:

$$w_\alpha = F^{-1}(\alpha) = \inf\{w: F(w) \geq \alpha\}$$

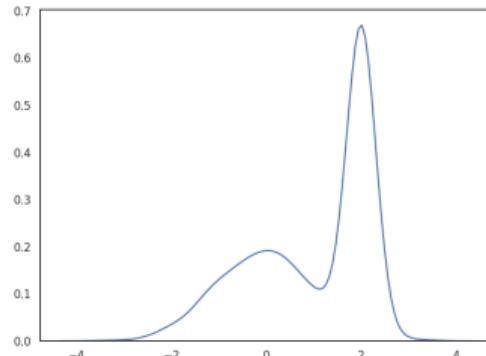
- **медиана** — квантиль порядка 0.5, центральное значение распределения:

$$\text{median}(w): p(w \leq \text{median}(w)) \geq 0.5, \quad p(w \geq \text{median}(w)) \geq 0.5$$

Мода

Точка максимума функции вероятности или плотности:

$$\text{mode}(w) = \arg \max_w f(w)$$



Распределение может иметь несколько мод:

$$w \sim \alpha_1 \mathcal{N}(\mu_1, \sigma_1^2) + \alpha_2 \mathcal{N}(\mu_2, \sigma_2^2).$$

Матожидание

Среднее значение случайной величины w :

$$\mathbb{E}w = \int w dF(w).$$

- Может быть не определено;
- линейно;
- не зависит от событий меры нуль;
- ЗБЧ:

$$\bar{w}_n \rightarrow_{n \rightarrow \infty} \mathbb{E}w;$$

- ЦПТ:

$$\sqrt{n} \frac{\bar{w}_n - \mathbb{E}w}{\sqrt{Dw}} \rightarrow \mathcal{N}(0, 1).$$

Матожидание: сходимость

Часто решается задача о сходимости матожидания сложной функции от случайно величины:

$$w \xrightarrow{d/p/\text{п.н.}} w^*,$$

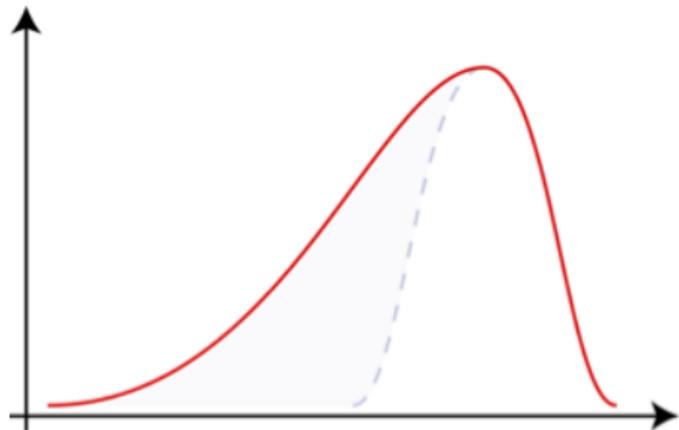
$$\mathbb{E}f(w) \rightarrow \mathbb{E}f(w^*)?$$

- f — непрерывная и ограниченная, тогда $\mathbb{E}f(w) \xrightarrow{d} \mathbb{E}f(w^*)$.
- f — непрерывна почти всюду, тогда $f(w) \xrightarrow{d/p/\text{п.н.}} f(w^*)$ (Теорема Манна-Вальда).
- Сходимость почти наверное: теорема Лебега о мажорируемой сходимости для переноса предела под знак матожидания.

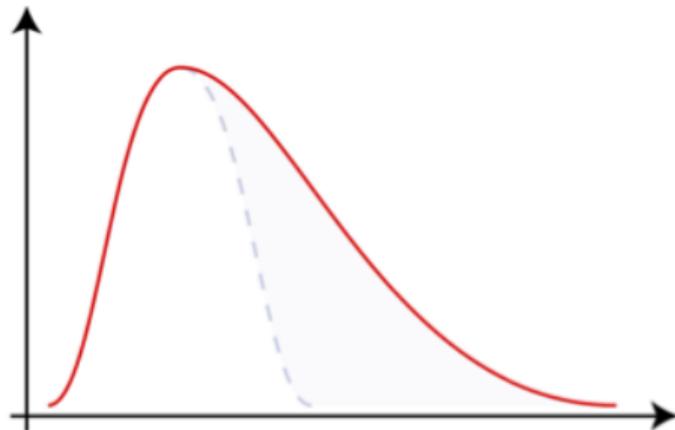
Прочие моменты

- Второй момент (дисперсия): $Dw = E(w - Ew)^2$ — мера разброса значений случайной величины.
- Третий момент: $\frac{E(w-Ew)^3}{Dw^{3/2}}$ — коэффициент асимметрии случайной величины.
- Четвертый момент $\frac{E(w-Ew)^4}{Dw^2} - 3$ — коэффициент эксцесса, мера остроты пика распределения случайной величины.

Прочие моменты

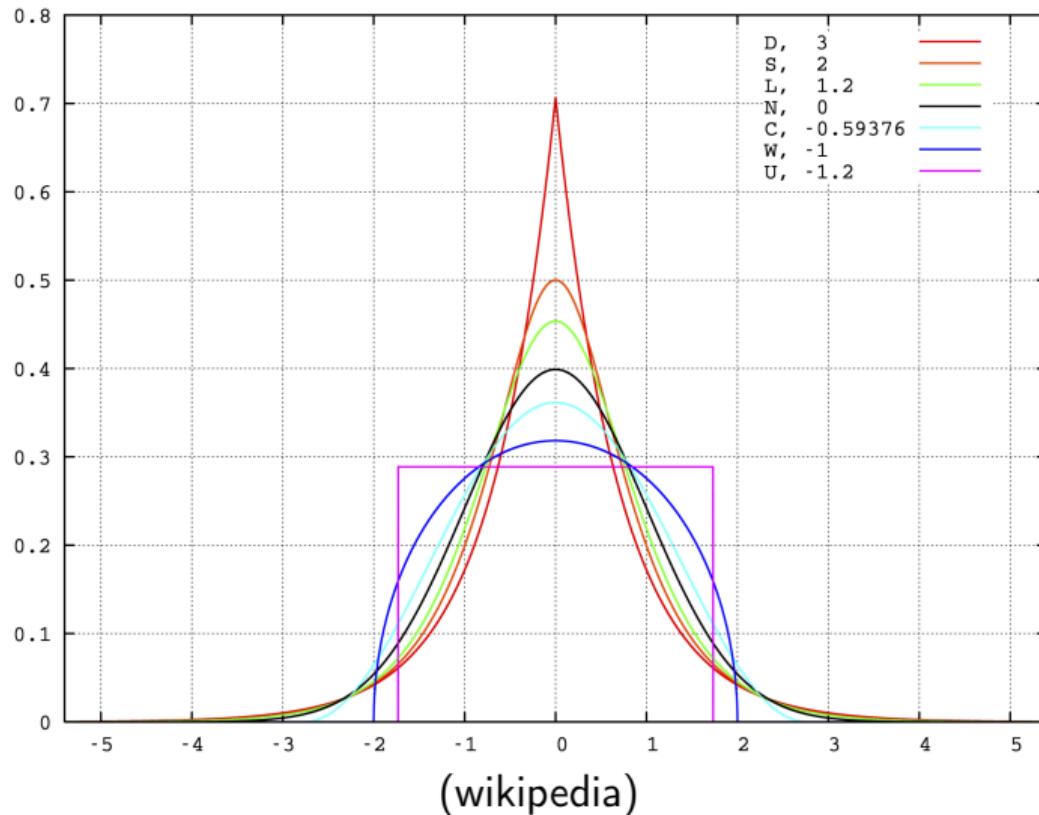


Negative Skew

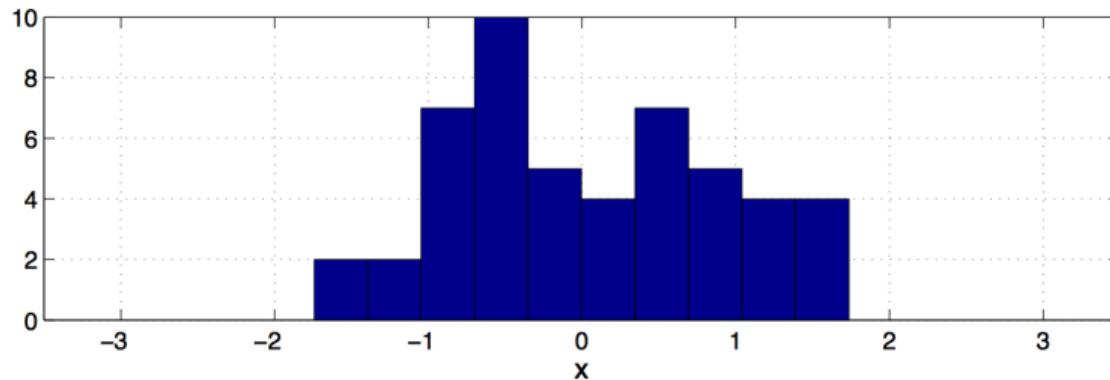
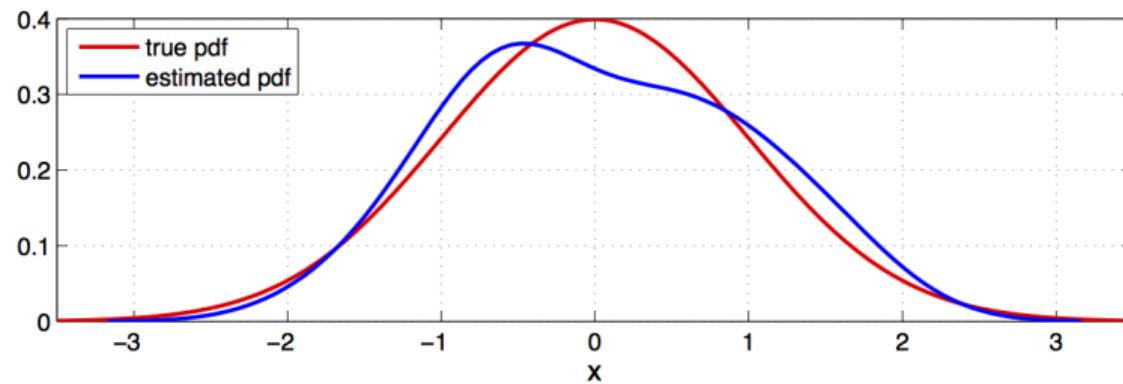


Positive Skew

Прочие моменты



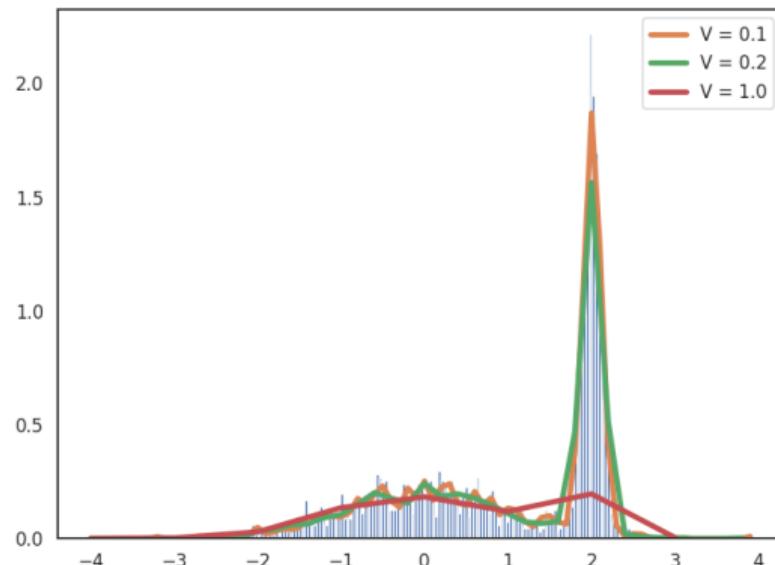
Оценка плотности распределения



KDE

Оценка строится с использованием ядерной функции k :

$$p(x) = \frac{1}{N} \sum_{x_i \in \mathbf{x}} \frac{1}{h} K\left(\frac{x - x_i}{h}\right)$$

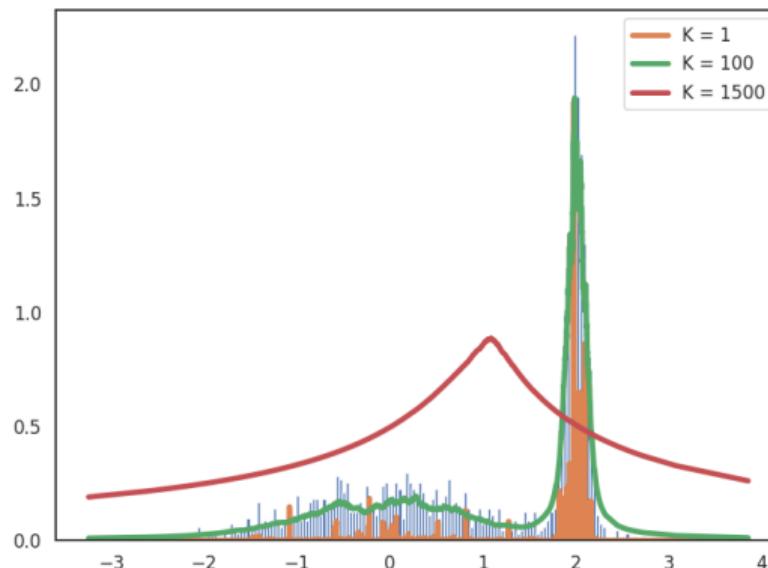


KDE

KNN как обобщение KDE:

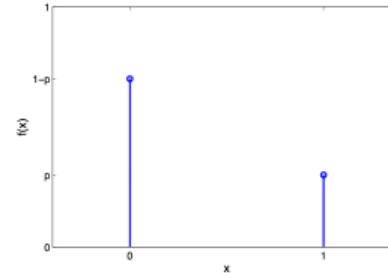
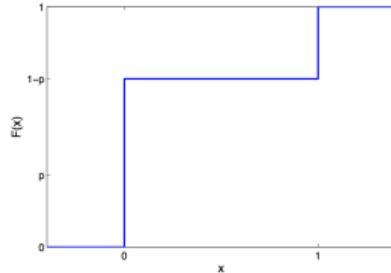
$$p(x) = \frac{1}{N} \sum_{x_i \in \mathbf{X}} \frac{1}{h} K\left(\frac{x - x_i}{h_i}\right),$$

$$h_i = \text{dist}(x_i, \text{neighbour}(x_i, K))$$



Распределение Бернулли

$w \in \{0, 1\} \sim Ber(p), \quad p \in (0, 1)$



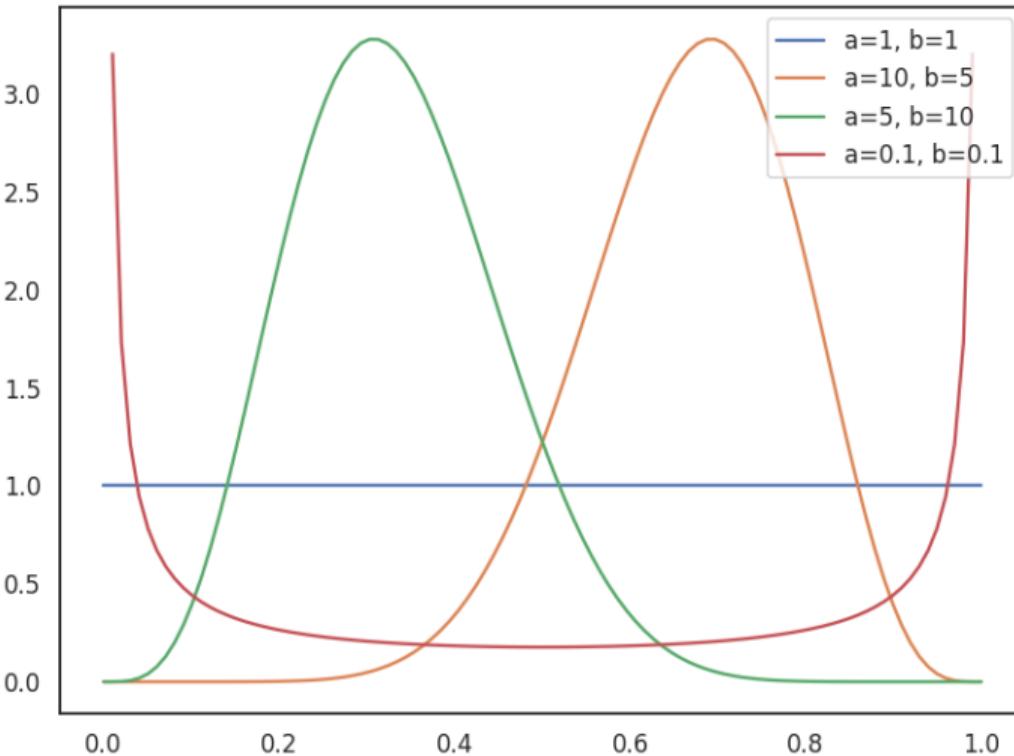
$$F(w) = \begin{cases} 0, & w < 0, \\ 1 - p, & 0 \leq w < 1, \\ 1, & w \geq 1. \end{cases}$$

$$f(w) = \begin{cases} 1 - p, & w = 0, \\ p, & w = 1. \end{cases}$$

- пример: результат подбрасывания монеты

Бета-распределение

$$p(w) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} w^{a-1} (1-w)^{b-1}$$



Бета-распределение

- соответствует *априорным* ожиданиям о распределении Бернулли
- интерпретация: “эффективное количество наблюдений $w = 1, w = 0$ ”
- при $n \rightarrow \infty$ сходится к δ -распределению в точке ОМП распределения Бернулли.

Мультиномиальное распределение

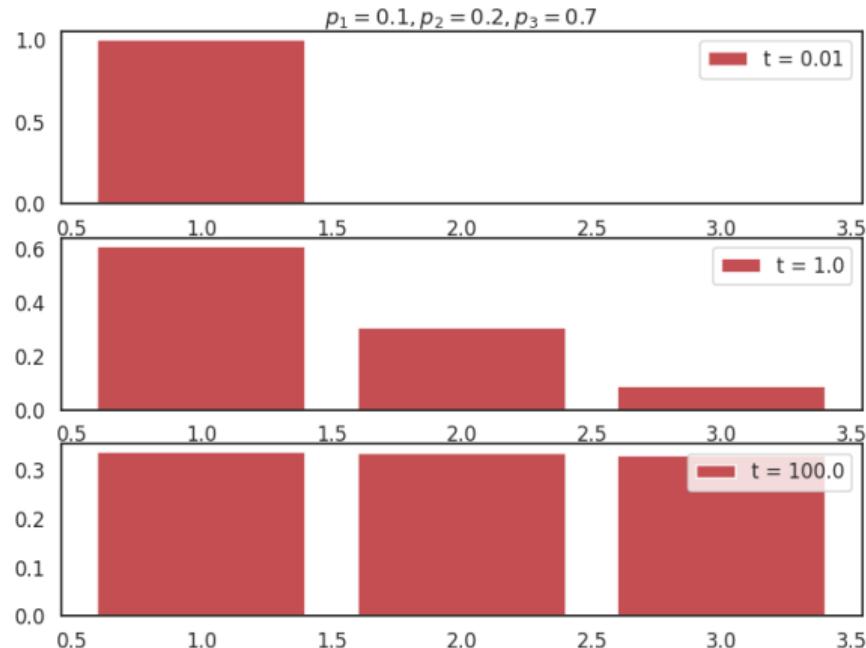
- Обобщение распределения Бернулли на большее количество событий:

$$p(w = w_i | p_1, \dots, p_n) = p_i.$$

- Возможная параметризация: через softmax:

$$\text{softmax}(\log p, t) = \frac{\exp(-\log p \cdot t^{-1})}{\sum_{i=1}^n \exp(-\log p_i \cdot t^{-1})}$$

Мультиномиальное распределение



Распределение Дирихле

$$p(w_1, \dots, w_K, \alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^K w_i^{\alpha_i - 1}$$

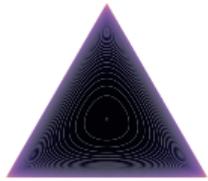
- Обобщение бета-распределения на многомерный случай
- Определяется на $K - 1$ -симплексе:

$$w_i \geq 0, \sum w_i = 1.$$

- Интерпретация: вероятность каждого из K взаимоисключающих событий равна w_i ; при условии, что каждое событие наблюдалось $\alpha_i - 1$ раз
- Альтернативная параметризация параметров:

$$\alpha = \bar{\alpha} \cdot t, \|\alpha\| = 1.$$

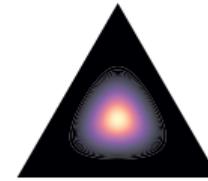
Распределение Дирихле



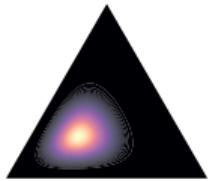
$\bar{\alpha} = [1, 1, 1]$, $t = 0.9$



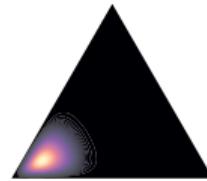
$t = 1.0$



$t = 10.0$



$\bar{\alpha} = [0.5, 0.25, 0.25]$, $t = 30.0$



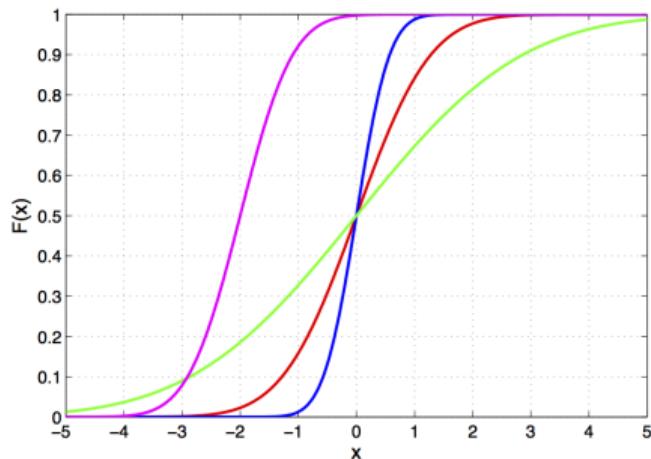
$[0.75, 0.125, 0.125]$



$[0.9, 0.05, 0.05]$

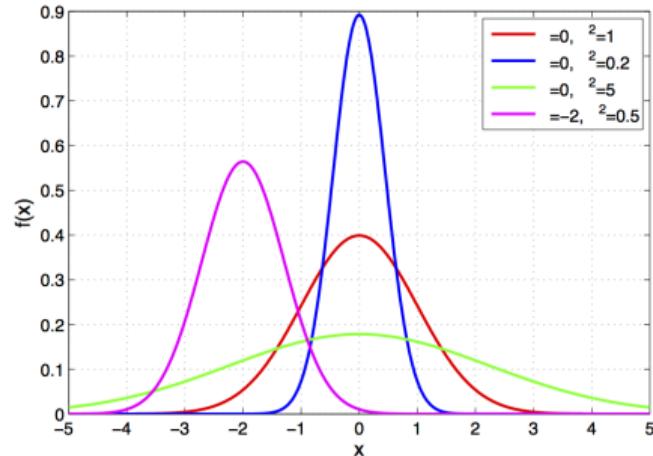
Нормальное распределение

$$w \in \mathbb{R} \sim \mathcal{N}(\mu, \sigma^2), \sigma^2 > 0$$



$$F(w) = \Phi\left(\frac{w - \mu}{\sigma}\right)$$

$$f(w) = \frac{1}{\sigma} \phi\left(\frac{w - \mu}{\sigma}\right)$$



$$\Phi(w) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^w e^{-\frac{t^2}{2}} dt$$

$$\phi(w) = \frac{1}{\sqrt{2\pi}} e^{-\frac{w^2}{2}}$$

Нормальное распределение

- предельное распределение суммы слабо взаимозависимых сл. в.
- $Ew = \text{median}(w) = \text{mode}(w) = \mu$, $Dw = \sigma^2$, все моменты более высокого порядка нулевые
- пусть w_1, \dots, w_n независимы, $w_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, тогда $\forall a_1, \dots, a_n$

$$\sum_{i=1}^n a_i w_i \sim \mathcal{N}\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

- Нормальное распределение имеет максимальную дифференциальную энтропию среди всех непрерывных распределений, дисперсия которых не превышает заданную величину.
- пример: погрешность измерения

Распределение стьюдента

- $Ew = 0$ при $\nu > 1$, $\text{median}(w) = \text{mode}(w) = 0$ всегда
- пусть $Z \sim N(0, 1)$ и $V \sim \chi^2_\nu$ независимы, тогда

$$T = \frac{Z}{\sqrt{V/\nu}} \sim St(\nu)$$

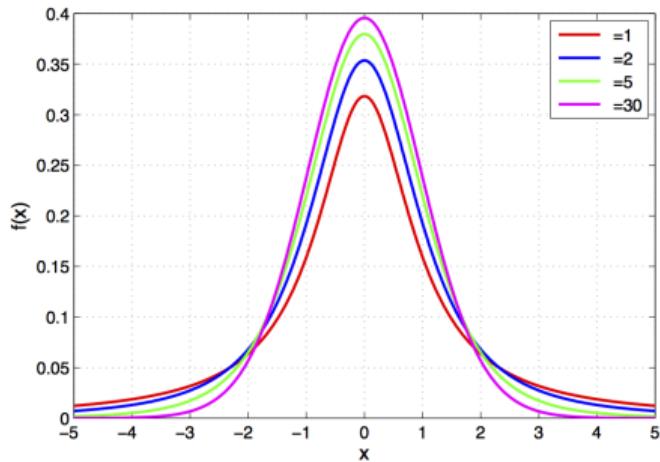
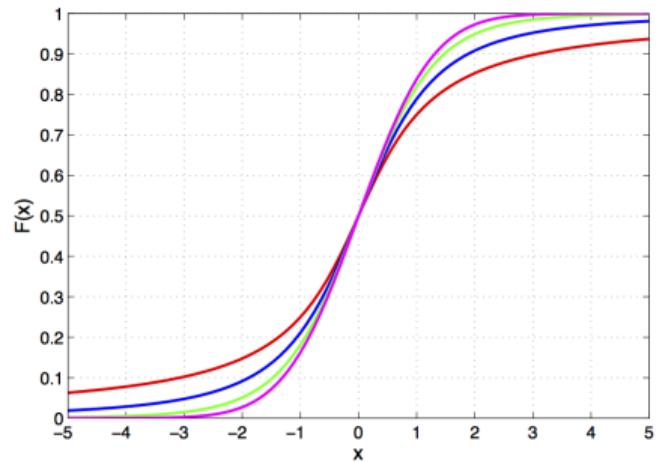
- если $w \sim St(\nu)$, то

$$Y = \lim_{\nu \rightarrow \infty} w \sim \mathcal{N}(0, 1)$$

- возникает при оценке среднего значения сл. в. с неизвестной дисперсией

Распределение стьюдента

$X \in \mathbb{R} \sim St(\nu), \nu > 0$



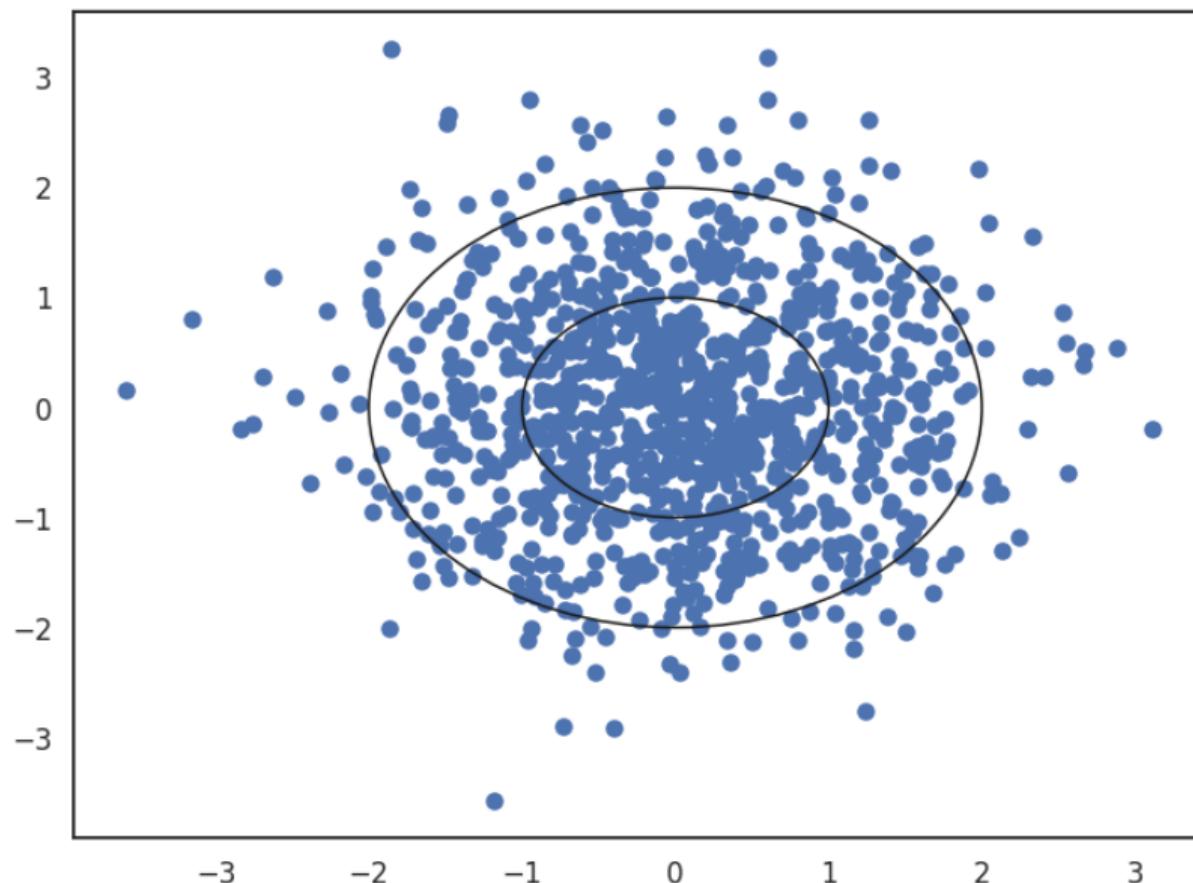
$$F(x) = \frac{1}{2} + x\Gamma\left(\frac{\nu+1}{2}\right)$$

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

Периодические распределения

- Наивный подход: использовать произвольное распределение для периодических данных
 - ▶ Пример, когда это плохо: выборка состоит из двух объектов на окружности: (1 градус и 359 градусов)
 - ▶ $Ew = 180$, $D = 179$

Периодические распределения



Периодические распределения

- Распределение фон Мизеса:

$$p = \frac{\exp(k \cos(x - \mu))}{2\pi I_0(k)}, \quad I_0 \text{ —функция Бесселя.}$$

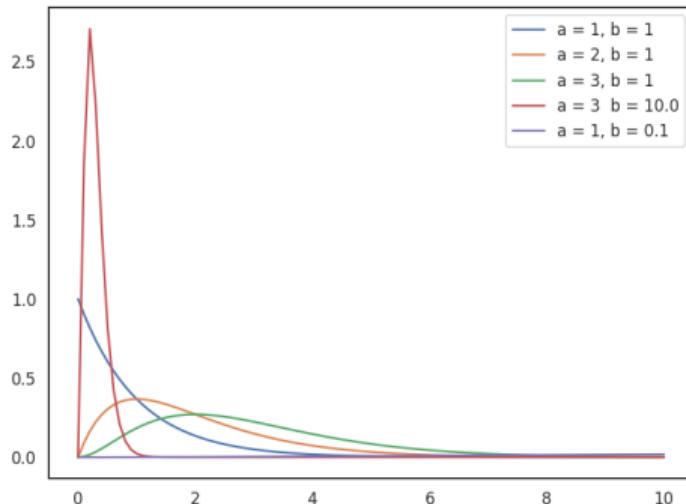
- Идея распределения:

- ▶ $[w_1, w_2] \sim \mathcal{N}(\mu, \sigma^2)$
- ▶ Параметризуем их через полярные координаты и ограничим радиус:

$$w_1 = r \cos \phi, w_2 = r \sin \phi, r = \text{Const.}$$

Гамма-распределение

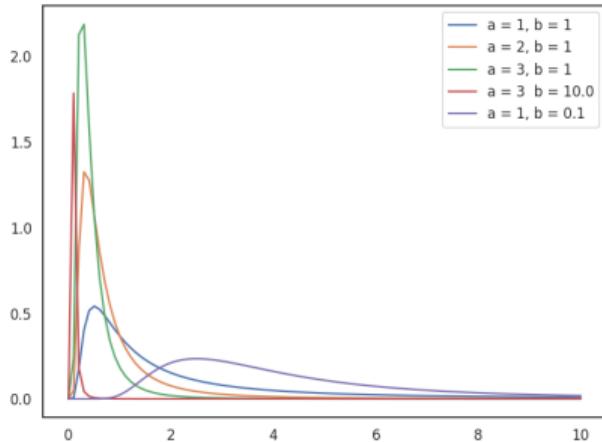
$$p(w, \alpha, \beta) = \frac{\beta^\alpha w^{\alpha-1} e^{-\beta}}{\Gamma(\alpha)}$$



- Используется для моделирования априорных предположений о величине, обратной среднеквадратичному отклонению.

Обратное гамма-распределение

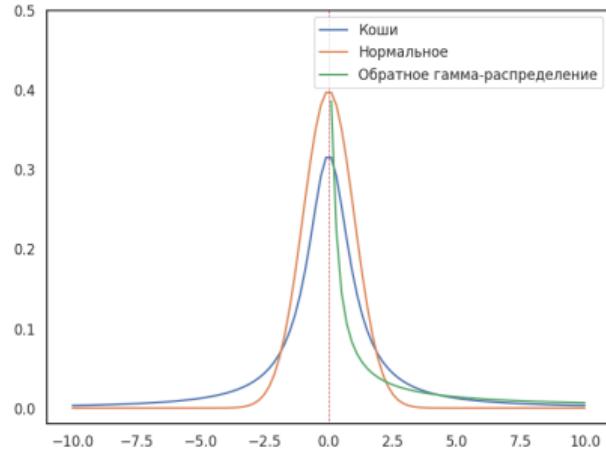
$$p(w, \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} w^{-\alpha-1} \exp(-\beta \cdot w^{-1}).$$



- $w \sim \Gamma(\alpha, \beta) \rightarrow w^{-1} \sim \text{Inv-Gamma}(\alpha, \beta^{-1})$
- Используется для моделирования априорных предположений о среднеквадратичном отклонении.

Распределение Коши

$$p(w, w_0, \gamma) = \frac{\gamma}{\pi ((w - w_0)^2 + \gamma^2)}.$$



- Используется как альтернатива нормальному распределению или обратному гамма-распределению
- Имеет тяжелые хвосты
- Моменты не определены

Литература и прочие ресурсы

- Ширяев А. Н. Вероятность-1. – МЦНМО, 2007. – С. 552-552.
- Bishop C. M. Pattern recognition //Machine learning. – 2006. – Т. 128. – №. 9.
- Минимизация KL: <https://wiseodd.github.io/techblog/2017/01/26/kl-mle/>
- Numpy
- Scipy