

Оптимизация и вариационный вывод

Веприков Андрей M05-402в

База: от маргинального правдоподобия к ELBO

Рассматриваем байесовскую модель с prior $p(\theta)$ и правдоподобием $p(D | \theta)$:

$$p(D, \theta) = p(D | \theta) p(\theta), \quad p(\theta | D) = \frac{p(D, \theta)}{p(D)}.$$

Маргинальное правдоподобие (доказательство модели):

$$\log p(D) = \log \int p(D, \theta) d\theta.$$

Вставим любую плотность $q(\theta)$ (вариационное распределение):

$$\log p(D) = \log \int q(\theta) \frac{p(D, \theta)}{q(\theta)} d\theta.$$

Применяя неравенство Йенсена, получаем вариационный нижний предел:

$$\log p(D) \geq \mathbb{E}_q[\log p(D, \theta) - \log q(\theta)] =: \mathcal{L}(q).$$

Тогда имеет место тождество:

$$\log p(D) = \mathcal{L}(q) + \text{KL}(q(\theta) \parallel p(\theta \mid D)),$$

и задача вариационного вывода формулируется как

$$q^* = \arg \max_q \mathcal{L}(q) = \arg \min_q \text{KL}(q(\theta) \parallel p(\theta \mid D)).$$

ELBO как баланс «качество — энтропия»

Разложим лог-совместное:

$$\mathbb{E}_q[\log p(D, \theta)] = \mathbb{E}_q[\log p(D | \theta)] + \mathbb{E}_q[\log p(\theta)].$$

Определим энтропию вариационного распределения:

$$S(q) = -\mathbb{E}_q[\log q(\theta)].$$

Тогда ELBO можно записать как

$$\mathcal{L}(q) = \underbrace{\mathbb{E}_q[\log p(D | \theta)]}_{\text{качество подгонки данных}} + \underbrace{\mathbb{E}_q[\log p(\theta)]}_{\text{согласованность с prior}} + S(q).$$

- $\mathbb{E}_q[\log p(D | \theta)] + \mathbb{E}_q[\log p(\theta)]$ — **качество аппроксимации постериора (fit + prior)**.
- $S(q)$ — **регуляризация сложности** вариационного распределения, препятствующая коллапсу q .

Оптимизация как вариационный вывод

Вариационный нижний предел:

$$\log p(x) \geq \mathcal{L}[q] = \underbrace{\mathbb{E}_q[\log p(\theta, x)]}_{\text{Energy}} + \underbrace{S[q]}_{\text{Entropy}}, \quad S[q] = -\mathbb{E}_q[\log q(\theta)].$$

Непараметрическое вариационное семейство, порождённое оптимизацией:

$$\theta_0 \sim q_0(\theta), \quad \theta_{t+1} = T(\theta_t), \quad q_t = T_{\#}^{(t)} q_0.$$

Требование: T биективно на области интереса.

Оценка ELBO по одной траектории оптимизатора

Из формулы замены переменных (Якобиан $J(\theta) = \frac{\partial T}{\partial \theta}$):

$$S[q_{t+1}] - S[q_t] = \mathbb{E}_{\theta_t \sim q_t} [\log |J(\theta_t)|].$$

Оценка $\mathcal{L}[q_T]$ по одной траектории $\{\theta_t\}_{t=0}^T$:

$$\hat{\mathcal{L}}[q_T] = \underbrace{\log p(\theta_T, x)}_{\text{энергия}} + \underbrace{\sum_{t=0}^{T-1} \log |J(\theta_t)|}_{\text{энтропия}} + S[q_0].$$

Пример для $q_0 = \mathcal{N}(0, \sigma_0^2 I_D)$:

$$S[q_0] = \frac{D}{2} (1 + \log 2\pi) + D \log \sigma_0.$$

SGD: изменение энтропии через $\log \det$ Якобиана

SGD-обновление для $L(\theta)$ (напр. $L(\theta) = -\log p(x | \theta)$):

$$\theta_{t+1} = \theta_t - \alpha \nabla L(\theta_t).$$

Якобиан шага и приращение энтропии:

$$J_t = I - \alpha H_t, \quad H_t = \nabla_{\theta}^2 L(\theta_t),$$

$$\Delta S_t \equiv S[q_{t+1}] - S[q_t] \approx \log |I - \alpha H_t|.$$

Ограничения на шаг: если $\alpha \lambda_{\max} < 1$, то J_t невырожден; при $\alpha \lambda_i \rightarrow 1 \Rightarrow \Delta S_t \rightarrow -\infty$ (схлопывание объёма).

Случай стохастических градиентов: при рандомизации минибатчей формула выше даёт *нижнюю* оценку ΔS_t , а итоговая $\hat{\mathcal{L}}$ остаётся истинным нижним пределом $\log p(x)$.

Линейная по D оценка $\log |I - \alpha H|$: параболическая нижняя грань

Спектральное разложение:

$$\log |I - \alpha H| = \sum_{i=1}^D \log(1 - \alpha \lambda_i) \geq \sum_{i=1}^D [-\alpha \lambda_i - (\alpha \lambda_i)^2],$$

важно при $\alpha \lambda_i \lesssim 1$. Следовательно,

$$\log |I - \alpha H| \geq -\alpha \operatorname{Tr}(H) - \alpha^2 \operatorname{Tr}(H^2).$$

Стохастические оценки следов (Hutchinson):

$$\operatorname{Tr}(H) = \mathbb{E}_{r \sim \mathcal{N}(0, I)} [r^\top H r], \quad \operatorname{Tr}(H^2) = \mathbb{E}_{r \sim \mathcal{N}(0, I)} [\|Hr\|_2^2].$$

Две «Гессиан-вектор» операции: оценка нижней грани для ΔS_t

Для фиксированного t и $r_0 \sim \mathcal{N}(0, I)$ вычислим:

$$r_1 = r_0 - \alpha(H_t r_0), \quad r_2 = r_1 - \alpha(H_t r_1).$$

Тогда

$$\widehat{\Delta S_t} = r_0^\top (-2r_0 + 3r_1 - r_2)$$

даёт *непредвзятую* оценку параболической нижней границы

$$\widehat{\Delta S_t} \approx -\alpha \operatorname{Tr}(H_t) - \alpha^2 \operatorname{Tr}(H_t^2),$$

используя лишь два произведения вида $H_t v$ (выполнимы за $O(D)$ при реверс-режиме автодифференцирования).

Инициализация и выбор целевой функции

Рекомендации статьи:

- **Инициализация:** q_0 взять равным prior $p(\theta)$; он обычно широк (высокая энтропия) и даёт корректный $S[q_0]$.
- **Целевая функция:** оптимизировать $L(\theta) = -\log p(x | \theta)$ (а не $-\log p(\theta, x)$).

Последствие: если параметр θ не влияет на правдоподобие, то

$$\frac{\partial}{\partial \theta} \log p(x | \theta) = 0 \Rightarrow (H)_{\phi,:} = 0$$

$\Rightarrow$ вклад этой координаты в ΔS_t равен 0.

Это избегает искусственного штрафа за «схлопывание» параметров, не влияющих на данные.

Entropy-friendly SGD

Покомпонентный warping градиента ($g = \nabla L(\theta)$):

$$g' = g - g_0 \tanh\left(\frac{g}{g_0}\right), \quad \theta_{t+1} = \theta_t - \alpha g'.$$

Связь Якобианов (компонентно, через диагональный множитель):

$$J'_t = D_g J_t, \quad D_g = \text{diag}\left(1 - \cosh^{-2}\left(\frac{g}{g_0}\right)\right), \quad J_t = I - \alpha H_t.$$

Приращение энтропии:

$$\Delta S_t \approx \log |J'_t| = \log |D_g| + \log |I - \alpha H_t|,$$

где $\log |D_g|$ отвечает за сохранение энтропии в «плоских» направлениях.

Итог: оценка нижней границы маргинального правдоподобия

Оценка по одной траектории длины T :

$$\widehat{\mathcal{L}}[q_T] = \log p(\theta_T, x) + S[q_0] + \sum_{t=0}^{T-1} \widehat{\Delta S}_t,$$

где

$$\widehat{\Delta S}_t = \begin{cases} \log |I - \alpha H_t|, & \text{малая размерность,} \\ r_0^\top (-2r_0 + 3r_1 - r_2), & \text{большая размерность.} \end{cases}$$

Ранняя остановка $\Leftrightarrow$ выбор T как максимизатора $\widehat{\mathcal{L}}[q_T]$.

SGD как стохастический процесс

Оптимизируем:

$$L(\theta) = \sum_{n=1}^S \ell_n(\theta), \quad g(\theta) = \nabla L(\theta).$$

Мини-батч градиент:

$$\hat{g}_S(\theta) = g(\theta) + \xi_S(\theta), \quad \mathbb{E}[\xi_S] = 0.$$

Допущения:

- A1: $\xi_S(\theta) \sim \mathcal{N}(0, \frac{1}{S} C)$ (CLT)
- A2: $C(\theta) \approx C$ вблизи минимума
- A3: шаг ε мал

Дискретный шаг SGD:

$$\theta_{t+1} = \theta_t - \varepsilon g(\theta_t) + \varepsilon \xi_S(\theta_t).$$

Переход к SDE

Обозначим $BB^T = C$. Тогда шум в SGD:

$$\varepsilon \xi_S \approx \sqrt{\frac{\varepsilon}{S}} B W_t, \quad W_t \sim \mathcal{N}(0, I).$$

Переход к непрерывному времени ($dt = \varepsilon$):

$$d\theta(t) = -g(\theta(t)) dt + \sqrt{\frac{\varepsilon}{S}} B dW(t).$$

Это анизотропное стохастическое Ланжевеновское уравнение.

Линеаризация и ОУ-процесс

Вблизи минимума $\theta^* = 0$:

$$L(\theta) \approx \frac{1}{2} \theta^\top A \theta, \quad A = \nabla^2 L(0).$$

Тогда

$$d\theta(t) = -A\theta(t) dt + \sqrt{\frac{\varepsilon}{S}} B dW(t).$$

Это многомерный процесс Орнштейна–Уленбека.

Стационарное распределение:

$$q(\theta) = \mathcal{N}(0, \Sigma),$$

где Σ решает уравнение Ляпунова:

$$A\Sigma + \Sigma A^\top = \frac{\varepsilon}{S} B B^\top.$$

Интерпретация как VI

Если

$$L(\theta) = -\log p(\theta, x),$$

то апостериорное распределение (квадратизированное):

$$p(\theta|x) \approx \mathcal{N}(0, A^{-1}).$$

Хотим: $q(\theta) = \mathcal{N}(0, \Sigma) \approx p(\theta|x)$.

KL:

$$\text{KL}(q\|p) = \frac{1}{2}(\text{Tr}(A\Sigma) - \log |A\Sigma| - d).$$

Заменяя Σ из Ляпунова, получаем зависимость KL от ε и S .

Оптимальные параметры SGD

Из подстановки Σ в KL получаем:

$$\text{KL}(q\|p) = \frac{\varepsilon}{2S} \text{Tr}(BB^\top) - \log\left(\frac{\varepsilon}{S}\right) + \text{const.}$$

Минимизация по ε :

$$\varepsilon^* = \frac{2S}{\text{Tr}(BB^\top)}$$

Для SGD с матричным шагом εH :

$$\theta_{t+1} = \theta_t - \varepsilon H \hat{g}_S,$$

KL минимизируется при

$$H^* \propto (BB^\top)_{\text{diag}}^{-1}$$

Вывод: оптимальный предобуславливатель инвертирует уровень шума. Это связывает SGD с AdaGrad/Fisher preconditioning.

SGD-шум: тяжёлые хвосты вместо Гаусса

Проблема: Традиционно шум SGD моделируют как Гауссовский:

$$\zeta_t = \frac{1}{B} \sum_{d \in \Omega_t} \nabla U^{(d)}(\theta_t) - \nabla U(\theta_t) \sim \mathcal{N}(0, \Sigma(\theta_t))$$

Новый взгляд: Эмпирика показывает *тяжёлые хвосты* — лучше подходит **симметричное α -устойчивое распределение (SaS Lévy)**:

$$\zeta_t \sim \text{SaS}(\alpha, \Sigma(\theta_t)), \quad \alpha \in (0.5, 2)$$

Ключевое наблюдение:

- Разные параметры θ_i имеют *разные* α_i (разная степень тяжести хвоста)
- Меньше $\alpha_i \Rightarrow$ чаще большие скачки $\Rightarrow$ легче выход из локального минимума

Эксперименты: ImageNet, CIFAR, Stable Diffusion, CLIP — в 95–99% параметров SaS лучше Гаусса

SDE-модель: каждый параметр — свой Lévy-процесс

Динамика SGD как СДУ в $\mathbb{R}^N$:

$$dW_t = -\frac{1}{\varepsilon} s_t \nabla U(W_t) dt + \frac{1}{\varepsilon} s_t \sum_{l=1}^N \sqrt{1^\top \Sigma_l(t)} r_l dL_t^l$$

где:

- $W_t \in \mathbb{R}^N$ — веса сети, s_t — scheduler (напр. $s_t = t^{\gamma-1}$), $\varepsilon = \eta^{-1}$
- L_t^l — одномерный SaS Lévy-процесс с параметром α_l для l -го параметра
- r_l — one-hot вектор (направление l -й координаты)

Разложение Lévy–Itô:

$$L_t^l = \xi_t^l + \psi_t^l$$

- ξ_t^l — *малые скачки* (бесконечно много, ограничены по амплитуде)
- ψ_t^l — *большие скачки* (compound Poisson, интенсивность $\beta_l(t)$)

Идея: Выход из локального минимума происходит из за больших скачков ψ_t^l

Среднее время выхода из локального минимума

Теорема 1 (экспоненциальный scheduler $s_t = t^{\gamma-1}$):

$$\mathbb{E}[\sigma_G] \approx \sum_{l=1}^N \frac{\Gamma(C_l)}{\beta_l^3 \cdot (\gamma-1)(\alpha_l-1) + 1} \cdot \beta_l^2 (m_l \Phi_l)^{-C_l}$$

где:

- σ_G — время первого выхода из области G (локальный минимум)
- $C_l = \frac{(\gamma-1)(\alpha_l-1)+2}{(\gamma-1)(\alpha_l-1)+1}$, $\Gamma(\cdot)$ — гамма-функция
- $\beta_l(t) = \frac{2}{\alpha_l} s_t^{\rho(\alpha_l-1)} \varepsilon_l^{\rho \alpha_l}$ — интенсивность больших скачков
- Φ_l — ширина Лосса (горизонтальное расстояние до границы)

Следствие (без scheduler, $\gamma \rightarrow 1$):

$$\mathbb{E}[\sigma_G] \propto \eta^{-(\alpha_l-1)} \cdot \Phi_l^{-1}$$

Вывод: Время выхода зависит от *ширины* Лосса (не высоты!),
полиномиально от η

Ось выхода: какой параметр помогает сбежать?

Теорема 2: Вероятность выхода через i -й параметр:

$$P(W_e \in \Omega_i^+(\delta)) \leq \sum_{l=0}^N A_l^{(i)} (d_l^+)^{-\alpha_l} \cdot \frac{\beta_l^2 (m_l \Phi_l)^{-C_l}}{\beta_l^3 \cdot (\gamma - 1)(\alpha_l - 1) + 1} \Gamma(C_l)$$

Следствие 2 (отношение вероятностей для двух параметров):

$$\frac{P(W_e \in \Omega_i^+(\delta))}{P(W_e \in \Omega_j^+(\delta))} \propto \eta^{\Delta_{i,j}}, \quad \Delta_{i,j} = \alpha_i - \alpha_j$$

Интерпретация:

- Параметры с *меньшим* α_i имеют **больше шансов** быть на пути выхода
- Эмпирика: слои ближе к выходу (классификатор) имеют меньше $\alpha \Rightarrow$ чаще участвуют в выходе

Эксперимент: 2D Ackley function с разными $\alpha_{x_1}, \alpha_{x_2}$ — выход чаще по оси с меньшим α

VSGD: вероятностная модель стохастического градиента

Идея VSGD: построить *явную байесовскую модель* для градиента.

Модель:

- Истинный градиент: $\mu_t = \nabla_{\theta} L(\theta_t)$.
- Наблюдаемый стохастический градиент:

$$g_t = \mu_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \Sigma_t).$$

- Ковариация шума Σ_t зависит от θ_t (аналог $C(\theta)$).

Задача: оценить постериор $p(\mu_t, \Sigma_t \mid g_{1:t})$ и использовать его для адаптивного выбора шага.

Байесовский вывод: постериор по истинному градиенту

Prior: $p(\mu_t) = \mathcal{N}(\mu_{t-1}, \Lambda_t^{-1})$, где Λ_t — точность (precision).

Правдоподобие: $p(g_t | \mu_t) = \mathcal{N}(g_t | \mu_t, \Sigma_t)$.

Постериор (по формуле Байеса для гауссиан):

$$p(\mu_t | g_t) = \mathcal{N}(\mu_t | m_t, V_t),$$

где

$$\begin{aligned} V_t^{-1} &= \Lambda_t + \Sigma_t^{-1}, \\ m_t &= V_t(\Lambda_t \mu_{t-1} + \Sigma_t^{-1} g_t). \end{aligned}$$

Интерпретация: m_t — взвешенное среднее между prior μ_{t-1} и наблюдением g_t , веса определяются точностями.

Упрощение: диагональная ковариация и SVI

Проблема: полный байесовский вывод требует обращения матриц размера $D \times D$.

Упрощение 1: диагональная ковариация $\Sigma_t = \text{diag}(\sigma_t^2)$.

Упрощение 2: стохастический вариационный вывод (SVI) — обновляем параметры постериора итеративно:

$$\begin{aligned}m_t &= (1 - \rho_t)m_{t-1} + \rho_t g_t, \\v_t &= (1 - \rho_t)v_{t-1} + \rho_t(g_t - m_t)^2,\end{aligned}$$

где $v_t = \sigma_t^2$ — оценка дисперсии шума, ρ_t — шаг SVI.

Связь с Adam: m_t — аналог первого момента, v_t — аналог второго момента.

Оценка уровня шума и адаптивный шаг

Ключевая идея: шаг оптимизации должен быть обратно пропорционален неопределённости градиента.

Вывод шага: из постериора $p(\mu_t \mid g_{1:t}) = \mathcal{N}(m_t, V_t)$ следует, что оптимальный шаг по координате k :

$$\eta_{t,k} \propto \frac{1}{\sqrt{V_{t,k}}}.$$

В диагональном случае $V_{t,k} \approx v_{t,k}$ (дисперсия шума), поэтому:

$$\eta_{t,k} \propto \frac{1}{\sqrt{v_{t,k}}}.$$

Обновление параметров:

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{m_t}{\sqrt{v_t} + \varepsilon},$$

где η — базовый шаг, ε — для численной стабильности.

Adam: обновление параметров

Координатно-зависимый шаг

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \varepsilon}}, \quad \varepsilon \sim 10^{-8}.$$

Интуиция формулы

$$\eta_k^{(t)} = \frac{\eta}{\sqrt{\hat{v}_{t,k}} + \varepsilon} \implies \begin{cases} \text{большой } \hat{v}_{t,k} \Rightarrow \text{малый шаг,} \\ \text{малый } \hat{v}_{t,k} \Rightarrow \text{большой шаг.} \end{cases}$$

- ❶ $\hat{m}_t$ задаёт *направление*,
- ❷ $\sqrt{\hat{v}_t}$ масштабирует его по каждой координате,
- ❸ η — глобальный learning-rate

Constant VSGD и связь с Adam

Constant VSGD: выбор гиперпараметров $\rho_t = \text{const}$ (аналог β_1, β_2 в Adam).

Сравнение с Adam:

Adam	VSGD
$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$	$m_t = (1 - \rho) m_{t-1} + \rho g_t$
$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$	$v_t = (1 - \rho) v_{t-1} + \rho (g_t - m_t)^2$
$\theta_{t+1} = \theta_t - \eta \frac{m_t}{\sqrt{v_t + \varepsilon}}$	$\theta_{t+1} = \theta_t - \eta \frac{m_t}{\sqrt{v_t + \varepsilon}}$

Отличие: в VSGD v_t оценивает дисперсию *шума градиента* $(g_t - m_t)^2$, а не второй момент g_t^2 .

Вывод: VSGD даёт байесовское обоснование Adam-подобным методам: адаптивный шаг возникает из постериорной неопределённости градиента.

L-BFGS: аппроксимация инвертированного Гессиана

Кривизна из двух последовательных точек

$$s_k = \theta_{k+1} - \theta_k, \quad y_k = \nabla L(\theta_{k+1}) - \nabla L(\theta_k), \quad \rho_k = \frac{1}{y_k^\top s_k}.$$

Формула Бафorsa–Гольдфарба–Шанно (BFGS) для B_{k+1}^{-1}

$$B_{k+1}^{-1} = (I - \rho_k s_k y_k^\top) B_k^{-1} (I - \rho_k y_k s_k^\top) + \rho_k s_k s_k^\top.$$

В L-BFGS храним *только* последние m пар (s_i, y_i) , а не полную матрицу $B_k^{-1} \in \mathbb{R}^{D \times D}$ ($m \ll D$ $O(mD)$ памяти).

L-BFGS: вычисление направления через two-loop recursion

Вход: градиент $g_k = \nabla L(\theta_k)$ и сохранённые пары $\{(s_i, y_i, \rho_i)\}_{i=k-m}^{k-1}$.
Первый цикл (идём *снизу вверх*)

$$q \leftarrow g_k; \quad \text{for } i = k-1, \dots, k-m: \quad \alpha_i = \rho_i s_i^\top q; \quad q \leftarrow q - \alpha_i y_i.$$

Начальная диагональ $B_k^0 = \gamma_k I$, $\gamma_k = \frac{s_{k-1}^\top y_{k-1}}{y_{k-1}^\top y_{k-1}}$ $r \leftarrow B_k^0 q$.

Второй цикл (обратно *сверху вниз*)

$$\text{for } i = k-m, \dots, k-1: \quad \beta_i = \rho_i y_i^\top r; \quad r \leftarrow r + s_i(\alpha_i - \beta_i).$$

Поисковое направление $d_k = -r$, шаг $\theta_{k+1} = \theta_k + \alpha_k d_k$

Pathfinder: вариационная аппроксимация вдоль траектории L-BFGS

Цель: построить нормальное приближение постериора $p(\theta | y)$, используя квази-Ньютоновскую траекторию оптимизации.

- Оптимизируем лог-плотность (лог-постериор)

$$\log p(\theta) = \log p(\theta | y) + \text{const.}$$

- L-BFGS генерирует траекторию

$$\theta^{(0:L)} = (\theta^{(0)}, \dots, \theta^{(L)}), \quad \theta^{(0)} \sim \pi_0.$$

- В каждой точке $\theta^{(l)}$ строим нормальную аппроксимацию

$$q^{(l)}(\theta) = \mathcal{N}(\theta | \mu^{(l)}, \Sigma^{(l)}),$$

используя квази-Ньютоновскую оценку обратного Гессiana $\Sigma^{(l)}$.

- Выбираем l по максимизации ELBO:

$$l^* = \arg \max_l \text{ELBO}(q^{(l)} \| p(\theta | y)) = \arg \min_l \text{KL}(q^{(l)} \| p(\theta | y)).$$

Локальная нормальная аппроксимация вдоль траектории

Шаг 1: квадратичное разложение.

В точке $\theta^{(l)}$ приближаем лог-плотность вторым порядком:

$$\log p(\theta | y) \approx \log p(\theta^{(l)} | y) + \nabla \log p(\theta^{(l)})^\top (\theta - \theta^{(l)}) - \frac{1}{2}(\theta - \theta^{(l)})^\top H^{(l)}(\theta - \theta^{(l)}),$$

где $H^{(l)} \approx -\nabla^2 \log p(\theta^{(l)})$ — Гессиан в точке $\theta^{(l)}$.

Шаг 2: Лапласовская форма.

Квадратичное выражение даёт гауссовское приближение:

$$\tilde{p}(\theta | y) \approx \mathcal{N}(\theta | \mu^{(l)}, (H^{(l)})^{-1}),$$

с

$$\mu^{(l)} = \theta^{(l)} + (H^{(l)})^{-1} \nabla \log p(\theta^{(l)}), \quad \Sigma^{(l)} = (H^{(l)})^{-1}.$$

Квази-Ньютоновская ковариация из L-BFGS

Шаг 3: откуда берётся $\Sigma^{(l)}$ в практике.

Точный $H^{(l)}$ вычислять дорого, поэтому:

- L-BFGS по истории шагов строит *оценку* обратного Гессiana,
- эта оценка записывается как

$$\Sigma^{(l)} \approx H(\theta^{(l)})^{-1} = \underbrace{\text{diag}(\alpha^{(l)})}_{\text{диагональ}} + \underbrace{\beta^{(l)}\gamma^{(l)}(\beta^{(l)})^\top}_{\text{низкий ранг}},$$

где вектор $\alpha^{(l)}$ и матрицы $\beta^{(l)}, \gamma^{(l)}$ восстанавливаются из шагов и градиентов (алгоритм α -RECOVER).

Итого: на каждом шаге траектории у нас есть локальное нормальное приближение

$$q^{(l)}(\theta) = \mathcal{N}(\theta \mid \mu^{(l)}, \Sigma^{(l)}),$$

где $\Sigma^{(l)}$ — квази-Ньютоновская оценка ковариации из L-BFGS.

Итоговая картина

Современные методы оптимизации можно понимать как вариационный вывод:

- **База:** ELBO как $\log p(D) = \mathcal{L}(q) + KL(q(\theta) \parallel p(\theta \mid D))$, баланс качества $\mathbb{E}_q[\log p(D, \theta)]$ и энтропии $H(q)$.
- **Неполная оптимизация:** траектория $\{\theta_t\}$ SGD задаёт вариационное семейство q_t и даёт оценку $\mathcal{L}(q_T)$; ранняя остановка $\Rightarrow$ выбор T , максимизирующего ELBO.
- **Pathfinder** и подобные методы: нормальные аппроксимации вдоль траектории квази-Ньютона дают явные вариационные семейства $q(\theta)$.
- **VSGD / Adam-подобные методы:** адаптивный шаг возникает из байесовской модели стохастического градиента g_t и постериорной неопределённости по $\nabla_{\theta} L(\theta)$.
- **SGD как стохастическая динамика:** SDE-предел и уравнение Фоккера–Планка показывают, что SGD генерирует стационарное распределение $q(\theta)$, аппроксимирующее апостериор $p(\theta \mid D)$.