The Description Length of Deep Learning Models

Léonard Blier, Yann Ollivier — NIPS 2018

Алябушев Павел

Bayesian multimodeling, МФТИ

2026

Вопрос статьи: сжимают ли данные сети с миллионами параметров?

- Принцип MDL и теория индукции Соломонова: хорошая модель — та, что хорошо сжимает данные *без потерь*, включая стоимость описания самой модели.
- Глубокие сети, на первый взгляд, противоречат принципу: параметров очень много.
- Свёрточные сети достигают 100% точности на обучающей выборке даже со *случайными* метками (Zhang et al., 2017).

Что делают авторы

Измеряют, сколько бит нужно, чтобы без потерь передать метки обучающей выборки вместе с моделью. Новых архитектур и алгоритмов обучения не предлагают.

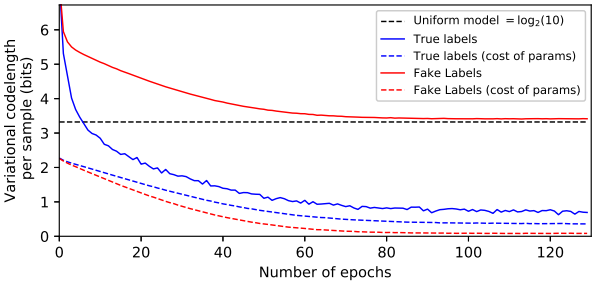
Вклад 1

Вариационный код (Hinton, van Camp, 1993) даёт неожиданно плохие оценки длины, хотя прямо минимизирует длину описания.

Вклад 2

Prequential-код поверх обычного обучения даёт оценки в 2–6 раз короче вариационных и лучше согласуется с точностью на тесте.

Случайные метки не сжимаются



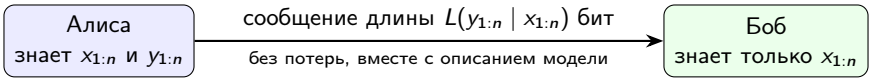
MNIST, MLP с 3 скрытыми слоями по 200 нейронов (ReLU), вариационное обучение. По оси y — вариационная длина кода на один пример, бит.

- Истинные метки: длина ниже равномерного кода $\log_2 10 \approx 3{,}32$ бит; около половины длины — информация в весах.
- Случайные метки: длина сходится к равномерному коду, вклад весов $\to 0$: обучения не произошло.

Предложение 2 (прил. A)

Если $Y_1, \ldots, Y_n$ равномерны на $\{1, \ldots, K\}$ и независимы, то с вероятностью $\geq 1 - 2^{-\delta}$ *любая* программа на фиксированной эталонной машине (она может зависеть от x, но не от Y) даёт $L(Y_{1:n} \mid x_{1:n}) \geq n \log_2 K - \delta - 1$.

Постановка: Алиса передаёт метки Бобу



Предложение 1 (код Шеннона–Хаффмана)

Если модель $p(y \mid x)$ заранее известна обоим, метки передаются за (с точностью до 1 бита на всю выборку)

$$L_p(y_{1:n} \mid x_{1:n}) = -\sum_{i=1}^{n} \log_2 p(y_i \mid x_i) \quad \text{— кросс-энтропия в битах.}$$

Равномерный код: $L^{\text{unif}} = n \log_2 K$.
MNIST: $60\,000 \cdot \log_2 10 \approx 199$ кбит.
CIFAR-10: $50\,000 \cdot \log_2 10 \approx 166$ кбит.
Коэффициент сжатия $= L / L^{\text{unif}}$.

Связь с взаимной информацией
Для префиксных кодов $\mathbb{E}_q[L] \geq H(y \mid x)$, поэтому $H(y) - \mathbb{E}_q[L] \leq I(y; x)$: сжатие меток — оценка $I(y; x)$ снизу. Классы почти сбалансированы, $H(y) \approx \log_2 K$.

Двухчастный код: сначала веса, потом метки

Определение 1 (two-part code)

$$L_{\theta^*}^{\text{2-part}}(y_{1:n} \mid x_{1:n}) = L_{\text{param}}(\theta^*) - \sum_{i=1}^{n} \log_2 p_{\theta^*}(y_i \mid x_i).$$

- float32: $L_{\text{param}}(\theta) = 32 \dim \theta$. Сеть с 10^6 параметров $\Rightarrow$ 32 Мбит, примерно в 200 раз больше равномерного кода на CIFAR-10.
- Практическое сжатие сетей (прунинг, квантизация, Han et al., 2015) — тот же двухчастный код с умным кодом для θ. Всё равно длиннее равномерного кода.
- Случайное аффинное подпространство размерности k (intrinsic dimension, Li et al., 2018): передаются seed и k координат.

Оценка снизу (только веса)	MNIST	CIFAR-10
float32, 2-part	$>$ 8,6 Мбит	$>$ 428 Мбит
Network compression	$>$ 400 кбит	$>$ 14 Мбит
Intrinsic dim. (точность 90% / 70%)	$>$ 9,28 кбит	$>$ 92,8 кбит

Вариационный и байесовский коды

Веса передаются с ограниченной точностью: неопределённость β задаёт точность передачи θ; с аргументом *bits-back* (Hinton, van Camp, 1993; Honkela, Valpola, 2004) это явная схема кодирования.

Определение 2 (variational code), prior α, любое распределение β

$$L_\beta^{\mathrm{var}}(y_{1:n} \mid x_{1:n}) = \mathrm{KL}(\beta \,\|\, \alpha) - \mathbb{E}_{\theta\sim\beta}\Big[\sum_{i=1}^{n} \log_2 p_\theta(y_i \mid x_i)\Big] \quad (= -\mathrm{ELBO} \text{ в битах}).$$

Байесовский код

$$L^{\mathrm{Bayes}} = -\log_2 \int p_\theta(y_{1:n} \mid x_{1:n})\, \alpha(\theta)\, d\theta,$$

$L_\beta^{\mathrm{var}} \geq L^{\mathrm{Bayes}}$, равенство $\iff$ β — апостериорное распределение.

Как считали (прил. C)

- $\beta = \mathcal{N}(\mu, \operatorname{diag}\sigma^2)$, $\sigma_i = \log(1 + e^{\rho_i})$
- prior $\alpha = \mathcal{N}(0, \sigma_0^2 I)$, $\sigma_0 = 0{,}05$ (подобран по лучшей длине)
- Монте-Карло с одним сэмплом ($S = 1$), библиотека Pyvarinf

Prequential (онлайн) код: веса не передаются вовсе



Определение 3 (prequential code), алгоритм 2

$$L^{\mathrm{preq}}(y_{1:n} \mid x_{1:n}) = t_1 \log_2 K + \sum_{s=1}^{S-1} -\log_2 p_{\hat{\theta}_{t_s}}\left(y_{t_s+1:t_{s+1}} \mid x_{t_s+1:t_{s+1}}\right).$$

- Боб сам обучает ту же модель на уже декодированных метках. Заранее согласуют модель, алгоритм обучения, гиперпараметры и seed ω.
- L^{preq} минус log-loss финальной модели на тех же обучающих данных — сколько информации о данных хранят обученные веса (по авторам).
- Блоки удваиваются: $t_s = 8, 16, \ldots, 32768$ (MNIST), $10, 20, \ldots, 40960$ (CIFAR-10); последний блок — до n.

Как ставили эксперименты

Данные: MNIST ($n = 60\,000$) и CIFAR-10 ($n = 50\,000$), $K = 10$. Передаются метки обучающей выборки; точность меряется на тесте.

Вариационный код: перебор полносвязных и свёрточных сетей; лучшими оказались небольшие сети (LeNet-подобные).

Prequential-код (Adam, lr $= 10^{-3}$; dropout 0,5 у сетей на MNIST и у свёрточных на CIFAR-10):

- MNIST: MLP 2×256; VGG-подобная сеть с 8 свёрточными слоями
- CIFAR-10: MLP 2×512; shallow (1×5000); tinyCNN (4 свёртки); VGG-подобная сеть с 13 свёртками: VGGa — без batch norm и аугментации, VGGb — с ними

Важно

Для вариационного и prequential-кодов выбирается модель с *лучшей длиной кода*, а не с лучшей точностью на тесте.

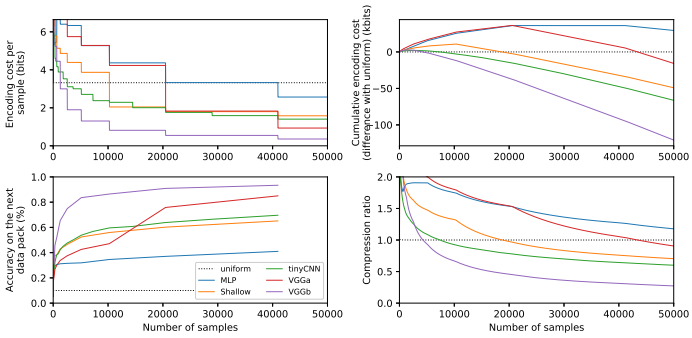
Главный результат: таблица 1

	MNIST			CIFAR-10		
Код	длина, кбит	сжатие	точность	длина, кбит	сжатие	точность
Uniform	199	1	10%	166	1	10%
float32 2-part	$>$ 8,6 Мбит	$>$ 45	98,4%	$>$ 428 Мбит	$>$ 2500	92,9%
Network compr.	$>$ 400	$>$ 2	98,4%	$>$ 14 Мбит	$>$ 83	93,3%
Intrinsic dim.	$>$ 9,28	$>$ 0,05	90%	$>$ 92,8	$>$ 0,56	70%
Variational	22,2	0,11	98,2%	89,0	0,54	66,5%
Prequential	**4,10**	**0,02**	**99,5%**	**45,3**	**0,27**	**93,3%**

Длина включает описание модели; «сжатие» — доля от длины равномерного кода.

- Prequential короче вариационного кода: в 2 раза на CIFAR-10 и в 5–6 раз на MNIST, и при этом точнее на тесте.
- float32 2-part и сжатие сетей длиннее равномерного кода даже как оценки снизу; intrinsic dim. — только оценка снизу и при точности 90% / 70%.

Prequential-код на CIFAR-10: длина следует за обобщением



Что на графиках (ось x — сколько примеров уже передано):

- слева: бит на пример и точность на следующем блоке;
- справа: накопленная длина минус равномерный код (кбит) и коэффициент сжатия на $[1; t_k]$.

Что видно

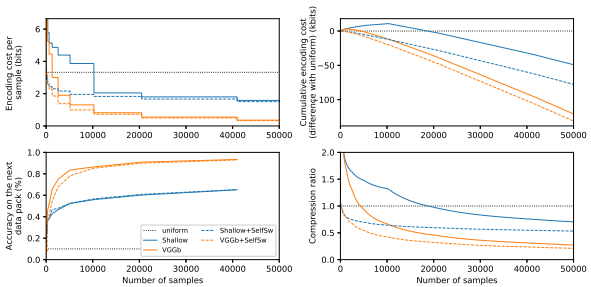
- лучше всех VGGb: 45,3 кбит (0,27);
- MLP на рисунке не опускается ниже равномерного кода;
- VGGa и VGGb — одна архитектура, разная процедура обучения, разная длина кода.

Catch-up и переключение между моделями

Catch-up (Van Erven et al., 2012): большая сеть переобучается на первых маленьких блоках и кодирует их хуже равномерного кода. VGGb: бит на пример ниже равномерного уже после 1000 примеров, а накопленное сжатие < 1 только после 5000.

Switch: на каждом блоке кодируем лучшей моделью из {uniform, tinyCNN, VGGa, VGGb}; последовательность переключений s передаётся за $-\log_2 \pi(s)$ бит, это пренебрежимо мало.

Self-switch: одна архитектура, выбираем число эпох $j \leq 10$ на каждом блоке — ранняя остановка как выбор модели.



Код (табл. 2)	MNIST, кбит	CIFAR-10, кбит
Prequential	4,10	45,3 (0,27)
Switch	4,05	**34,6** (0,21)
Self-switch	4,05	34,9 (0,21)

Почему это неожиданно: в теории коды эквивалентны

Классическая асимптотика (Grünwald, 2007)

Если модель d-мерная и идентифицируемая, данные порождены ею самой, prior подходящий, а эффективная размерность обученной модели не меньше d, то двухчастный, байесовский и prequential-код (на оценке ML или MAP) асимптотически эквивалентны:

$$L(y_{1:n} \mid x_{1:n}) = nH(Y \mid X) + \frac{d}{2}\log_2 n + O(1) \qquad \text{— критерий BIC.}$$

- Поэтому заранее не было причин ждать, что prequential-код окажется на порядок лучше.
- Глубокие сети не удовлетворяют *ни одному* из этих условий.
- Prequential-код строится не на ML-оценке, а на обучении с регуляризацией (dropout, ранняя остановка).

Вывод авторов

С точки зрения теории информации *число параметров само по себе не мешает сжатию* (гипотеза Чейтина: «понимание — это сжатие»).

Почему вариационный код проигрывает: открытый вопрос

Вариационные методы плохи *даже по собственному критерию* — длине описания. Зазор до байесовского кода — стандартное тождество ELBO:

$$L_\beta^{\mathrm{var}} = L^{\mathrm{Bayes}} + \mathrm{KL}\big(\beta \,\big\|\, p_{\mathrm{Bayes}}(\theta \mid x_{1:n}, y_{1:n})\big)$$

Возможные причины по авторам

1. Оптимизация параметров β несовершенна.
2. Даже лучшее β^* из класса (диагональная гауссиана) плохо приближает апостериорное распределение, и KL велик.
3. Prior, по мнению авторов, не главный фактор: гауссовы prior-ы с разной дисперсией и сопряжённый гауссов prior дали похожие результаты.
4. Сам точный байесовский код может быть длиннее prequential: недообучение параметрического байесовского вывода, catch-up, консерватизм байесовского выбора моделей.

Наблюдение: минимум вариационной длины выбирает *меньшие* сети, чем кросс-валидация, и они хуже на тесте.

Что получилось и где слабые места

Выводы авторов

- Глубокие сети сжимают метки с учётом стоимости модели: до 0,02 от равномерного кода на MNIST и до 0,21 на CIFAR-10 (switch).
- Число параметров не мешает сжатию.
- Двухчастный код с float32 и практическое сжатие сетей длиннее равномерного кода.
- Вариационный код в 2–6 раз длиннее prequential-кода, а модели хуже на тесте; почему — открытый вопрос.

Ограничения

- Только классификация на MNIST и CIFAR-10 ($K = 10$).
- Длина prequential-кода зависит от алгоритма обучения: у VGGa и VGGb одна архитектура, но разная длина.

Литература

[1] Blier L., Ollivier Y. *The description length of deep learning models.* NIPS 2018.

[2] Grünwald P. D. *The Minimum Description Length Principle.* MIT Press, 2007.

[3] Solomonoff R. *A formal theory of inductive inference.* Information and Control, 1964.

[4] Hinton G. E., van Camp D. *Keeping neural networks simple by minimizing the description length of the weights.* COLT 1993.

[5] Honkela A., Valpola H. *Variational learning and bits-back coding.* IEEE Trans. Neural Networks, 2004.

[6] Graves A. *Practical variational inference for neural networks.* NIPS 2011.

[7] Blundell C. et al. *Weight uncertainty in neural networks.* ICML 2015.

[8] Dawid A. P. *Statistical theory: the prequential approach.* JRSS A, 1984.

[9] Van Erven T., Grünwald P., de Rooij S. *Catching up faster by switching sooner.* JRSS B, 2012.

[10] Zhang C. et al. *Understanding deep learning requires rethinking generalization.* ICLR 2017.

[11] Li C. et al. *Measuring the intrinsic dimension of objective landscapes.* 2018.

[12] Han S., Mao H., Dally W. J. *Deep compression: compressing deep neural networks with pruning, trained quantization and Huffman coding.* 2015.

Два вопроса к аудитории

1. Почему в prequential-коде не нужно передавать веса сети и что Алиса и Боб должны согласовать заранее?
2. Сеть выучила случайные метки до 100% точности на обучающей выборке. Почему эти метки всё равно нельзя сжать?

Спасибо за внимание!