

Is Gibbs sampling faster than Hamiltonian Monte Carlo on GLMs?

Son Luu, Zuheng Xu, Nikola Surjanovic, Miguel Biron-Lattes,
Trevor Campbell, Alexandre Bouchard-Côté

Иванов Максим

ИАД, МФТИ

2026

Мотивация. Сколько стоит полезный сэмпл?

- 1) Байесовская регрессия даёт распределение коэффициентов и неопределённость прогноза.
- 2) При тысячах признаков точное интегрирование заменяют MCMC.
- 3) HMC использует градиенты и совместные перемещения параметров.
- 4) Gibbs обновляет координаты по очереди, стоимость зависит от реализации.

Задача статьи

Ускорить по координатным вычислениям для GLM и сравнить Gibbs с HMC по времени получения эффективных наблюдений.

$$\text{время на эффективный сэмпл} = \text{время итерации} \times \frac{\text{число итераций}}{\text{ESS}}.$$

Постановка задачи

Данные: $X \in \mathbb{R}^{n \times d}$, строки $x_i^\top$, отклики y_i ; параметры $\theta \in \mathbb{R}^d$.

$$\eta_i = x_i^\top \theta, \quad \mathbb{E}[Y_i \mid x_i, \theta] = \mu(\eta_i), \quad \pi(\theta \mid X, y) \propto \pi_0(\theta) \prod_{i=1}^n f(y_i \mid \mu(\eta_i)).$$

Пример: логистическая регрессия

$$y_i \sim \text{Bernoulli}(p_i), \quad p_i = \frac{1}{1 + e^{-\eta_i}}, \quad \theta_j \sim \mathcal{N}(0, 10^2).$$

$$\log \pi(\theta \mid X, y) = \sum_{i=1}^n [y_i \eta_i - \log(1 + e^{\eta_i})] - \frac{\|\theta\|^2}{200} + C.$$

Цель: генерировать состояния цепи с инвариантным распределением π .

Алгоритмы для сравнения

Gibbs: проход по координатам

$$\theta'_j \sim \pi(\theta_j \mid \theta_{-j}, X, y).$$

Один проход: последовательно обновить все d координат. В экспериментах статьи внутри координаты используется **slice sampling**.

НМС: движение по траектории

$$U(\theta) = -\log \pi(\theta), \quad H = U + \frac{1}{2} p^\top M^{-1} p.$$

Численное интегрирование и шаг Метрополиса.

$$\text{ESS}_f \approx \frac{T}{1 + 2 \sum_{k \geq 1} \rho_f(k)}, \quad f(\theta) = \theta_j \text{ или } \theta_j^2.$$

T — длина стационарной цепи; $\rho_f(k)$ — автокорреляция на лаге k .

Потери времени: повторный подсчёт $X\theta$


При изменении θ_j меняются все n слагаемых правдоподобия. Однако в каждом скалярном произведении меняется лишь одно слагаемое:

$$\eta_i = \underbrace{x_{i1}\theta_1 + \cdots + x_{ij}\theta_j + \cdots + x_{id}\theta_d}_{d \text{ слагаемых}}.$$

Вычисление	Полный пересчёт	С кэшем $\eta = X\theta$
Одна модель после изменения θ_j	$O(d)$	$O(1)$
Одно вычисление правдоподобия	$O(nd)$	$O(n)$
Проход по d координатам	$O(nd^2)$	$O(nd)$

Стоимость прохода указана при ограниченном среднем числе вычислений плотности на координату; кэш занимает дополнительно $O(n)$ памяти.

Compute graph Gibbs: обновляем только изменившийся вклад



Числовой пример для одного наблюдения

$x_i = (2, -1, 3)$, $\theta = (1, 2, 0)$, поэтому $\eta_i = 0$. Меняем вторую координату: $\theta'_2 = 5$.

$$\eta'_i = 0 + (-1)(5 - 2) = -3, \quad p'_i = \frac{1}{1 + e^3} \approx 0.047.$$

Тождественное преобразование: кэш не приближает плотность и не меняет целевое распределение.

Один проход CGGibbs: как использовать кэш

Инициализация: вычислить $\eta \leftarrow X\theta$ за $O(nd)$.

Для $j = 1, \dots, d$:

- 1) Зафиксировать текущее $a = \theta_j$ и кэш η .
- 2) Вычислить логарифм условной плотности для пробного z :

$$g_j(z) = \log \pi_{0,j}(z) + \sum_{i=1}^n \ell_i(\eta_i + x_{ij}(z - a)).$$

- 3) Сделать одномерный шаг, сохраняющий условное распределение, и получить b .
- 4) Сохранить $\eta \leftarrow \eta + X_{:j}(b - a)$ и $\theta_j \leftarrow b$.

Здесь $\pi_0(\theta) = \prod_j \pi_{0,j}(\theta_j)$, $\ell_i(u) = \log f(y_i \mid \mu(u))$. Пробные значения не перезаписывают основной кэш.

Про геометрию

Для $\pi = \mathcal{N}(m, \Sigma)$ число обусловленности

$$\kappa = \frac{\lambda_{\max}(\Sigma)}{\lambda_{\min}(\Sigma)}, \quad \kappa_r = \inf_{A - \text{невыр. диаг.}} \kappa(A\Sigma A^\top) \leq \kappa.$$

Разные масштабы координат

$\Sigma = \text{diag}(1, 100)$: $\kappa = 100$, но $\kappa_r = 1$.

Точный Gibbs нечувствителен к растяжению вдоль координатных осей.

Сильные корреляции

$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$: $\kappa_r = \kappa = (1 + \rho)/(1 - \rho)$ для $0 < \rho < 1$.

Диагональным масштабированием корреляцию не устранить.

Теория: преимущество зависит от геометрии


Теорема 4.1 и предложение 4.2: область применимости

$\pi = \mathcal{N}(m, \Sigma)$, $Q = \Sigma^{-1}$, $Q_{ij} \leq 0$ при $i \neq j$; точный Gibbs с фиксированным порядком. Для фиксированного старта x и t полных проходов:

$$D(K^t(x, \cdot), \pi) = O\left(e^{-t/\kappa_r}\right), \quad t \rightarrow \infty, \quad D \in \{\text{TV}, W_1, W_2, \chi^2\}.$$

Метод	Затраты
CGGibbs	$O(d\kappa_r)$
HMC	$O(d^{5/4}\sqrt{\kappa})$

Эксперимент 1: стоимость прохода растёт линейно



Синтетическая логистическая регрессия, $\theta_j \sim \mathcal{N}(0, 10^2)$.

По горизонтали: число параметров d .

По вертикали: секунды на 1000 проходов; меньше — лучше.

Обе шкалы логарифмические.

Результат: CGGibbs близок к $O(d)$; MultiBUGS, JAGS и Gen.jl — к $O(d^2)$.


Эксперимент 2: реальные задачи классификации

Пример	n	Число признаков	Приложение
colon	62	2 000	Экспрессия генов
GLI_85	85	22 283	Экспрессия генов
BASENOCK	1 993	4 862	Тексты
gisette	7 000	5 000	Распознавание цифр

Результат

CGGibbs эффективнее Stan NUTS на 11 из 12 наборов, в лучшем случае ускорение по времени на ESS — порядка 300×.

Пример colon: преимущество зависит от размерности



$x: \log_2 d.$

$y: \log_2(\text{секунды на ESS});$ **меньше**
— **лучше.**

Время адаптации исключено.

Результат: NUTS быстрее при малом d ; при большом d выигрывает CGGibbs.

- 1) Кэш $X\theta$ снижает стоимость прохода Gibbs: $O(nd^2) \rightarrow O(nd)$.
- 2) Для эффективности важны и размерность, и остаточная обусловленность.
- 3) CGGibbs убедителен в высокоразмерных GLM, универсального победителя нет.

Статья-источник

Son Luu, Zuheng Xu, Nikola Surjanovic, Miguel Biron-Lattes, Trevor Campbell, Alexandre Bouchard-Côté.
Is Gibbs sampling faster than Hamiltonian Monte Carlo on GLMs? arxiv.org/abs/2410.03630