Functional Variational Bayesian Neural Networks

Sun, Zhang, Shi, Grosse — ICLR 2019 (arXiv:1903.05779)

Chirkov George

Bayesian multimodeling, МФТИ

2026

Почему вывод в пространстве весов работает плохо

Bayesian neural networks (BNN): prior $p(\mathbf{w})$, likelihood $p(\mathcal{D} \mid \mathbf{w})$, posterior $p(\mathbf{w} \mid \mathcal{D})$ невычислим $\Rightarrow$ вариационный вывод, например Bayes by Backprop (BBB): $q(\mathbf{w}) = \mathcal{N}(\boldsymbol{\mu}, \operatorname{diag} \boldsymbol{\sigma}^2)$.

Проблемы VI в пространстве весов

- Prior-ы неосмысленны. Веса связаны с вычисляемой функцией сложным образом; на практике $\mathcal{N}(0, I)$ берут для удобства.
- Posterior трудно приблизить. Между весами сильные зависимости, а q (почти) факторизована.
- Деградация при росте ёмкости. Чем больше сеть, тем сложнее вывод и больше description length у posterior. На $y = x^3$ (20 точек) предсказания BBB резко меняются с размером сети.

Разрыв: GP-prior-ы кодируют богатую структуру (гладкость, периодичность), но масштабируются как $O(N^3)$; BNN масштабируются, но их prior-ы неинтерпретируемы.

Идея: неопределённость над функциями, а не над весами

Идея

Вариационный вывод напрямую над распределениями по функциям: prior — стохастический процесс, приближённый posterior — стохастическая нейросеть.

Что мы получаем

- структурные prior-ы: GP (периодичность, гладкость) и *implicit* процессы (кусочные функции)
- явные сэмплы функций из posterior (Thompson sampling, entropy search)
- предсказания стабильны при росте сети
- масштабируемость: данные входят только через ожидаемый log-likelihood (мини-батчи)

Вклад статьи

1. Теорема: KL между процессами = supremum маргинальных KL по конечным наборам точек
2. Functional ELBO (fELBO) как игра типа GAN; sampling-based версия
3. Оценка градиентов через spectral Stein gradient estimator (SSGE)
4. Эксперименты: экстраполяция, UCI-регрессия, bandits, Bayesian optimization

Что именно мы хотим посчитать

Данные: $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, likelihood $p(\mathcal{D} \mid f) = \prod_i p(y_i \mid f(\mathbf{x}_i))$.

Prior: стохастический процесс p над функциями $f : \mathcal{X} \to \mathcal{Y}$ (GP или implicit процесс без плотности).

Вариационное семейство: стохастическая сеть с шумом ξ, общим для всех входов

$$f(\mathbf{x}) = g_\phi(\mathbf{x}, \xi), \qquad \xi \sim p(\xi) \quad \text{(epistemic uncertainty)}.$$

Цель: максимизировать functional ELBO

$$\mathcal{L}(q) = \mathbb{E}_q\big[\log p(\mathcal{D} \mid f)\big] - \mathrm{KL}[q \,\|\, p].$$

Сравнение с пространством весов

$\mathcal{L}_q = \mathbb{E}_q[\log p(\mathcal{D} \mid \mathbf{w})] - \mathrm{KL}[q(\mathbf{w}) \| p(\mathbf{w})]$.

Сложности: (i) $\mathrm{KL}[q\|p]$ между процессами не имеет вида $\int q \log \frac{q}{p}$; (ii) плотность q над f невычислима; (iii) prior может быть implicit.

Как измерить расстояние между двумя процессами

Процесс характеризуется согласованными конечномерными маргиналами (теорема Колмогорова о продолжении: exchangeability и consistency).

Теорема 1 (Functional KL)

Для двух стохастических процессов P и Q

$$\mathrm{KL}[P \,\|\, Q] = \sup_{n \in \mathbb{N},\ \mathbf{X} \in \mathcal{X}^n} \mathrm{KL}[P_{\mathbf{X}} \,\|\, Q_{\mathbf{X}}].$$

Почему: σ-алгебра из теоремы о продолжении порождена цилиндрическими множествами, зависящими лишь от конечного числа точек.

Следствие. Для measurement set $\mathbf{X}$ и $\mathcal{L}_{\mathbf{X}}(q) := \mathbb{E}_q \sum_i \log p(y_i \mid f(\mathbf{x}_i)) - \mathrm{KL}[q(\mathbf{f}^{\mathbf{X}}) \| p(\mathbf{f}^{\mathbf{X}})]$

$$\mathcal{L}(q) = \inf_{n,\ \mathbf{X} \in \mathcal{X}^n} \mathcal{L}_{\mathbf{X}}(q).$$

$\Rightarrow$ антагонистическая игра с нулевой суммой: один игрок выбирает сеть q, противник — measurement set (как в GAN).

В каких точках смотреть на функции

Adversarial (как в GAN)

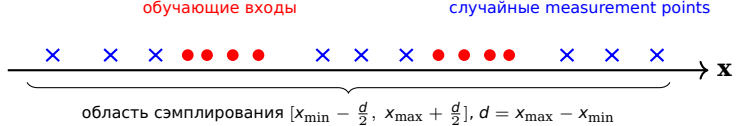
$$\max_q \min_{\mathbf{X} \in \mathcal{X}^m} \mathcal{L}_{\mathbf{X}}(q)$$

- худшие точки лежат рядом с обучающими данными
- ничто не заставляет q следовать структуре prior в других областях $\Rightarrow$ плохое обобщение

Sampling-based (используется в fBNN)

$$\max_q \mathbb{E}_{\mathbf{X}^M \sim C} \mathcal{L}_{\mathbf{X}^M, \mathbf{X}^{D_s}}(q)$$

- $\mathbf{X}^{D_s}$: случайный мини-батч обучающих точек
- $\mathbf{X}^M$: M случайных точек из интересующей области (c)
- согласуем сеть с prior и рядом с данными, *и* там, где нужны предсказания



Когда objective — настоящая нижняя граница

Теорема 2 (Lower bound)

Если measurement set $\mathbf{X}$ содержит все обучающие входы $\mathbf{X}^D$, то

$$\mathcal{L}_{\mathbf{X}}(q) = \log p(\mathcal{D}) - \mathrm{KL}\big[q(\mathbf{f}^{\mathbf{X}}) \,\|\, p(\mathbf{f}^{\mathbf{X}} \mid \mathcal{D})\big] \;\le\; \log p(\mathcal{D}).$$

При $\mathbf{X} = \{\mathbf{X}^D, \mathbf{X}^M\}$: максимизация $\mathcal{L}_{\mathbf{X}}(q) \Leftrightarrow$ минимизация KL до истинного posterior в этих точках (то же тождество ELBO, что на лекции).

Следствие 3 (Consistency)

Если истинный posterior $p(f \mid \mathcal{D})$ — GP, $\mathcal{Q}$ — все GP, $M > 1$ и $\mathrm{supp}(c) = \mathcal{X}$, то оптимумы и adversarial, и sampling-based задач равны $p(f \mid \mathcal{D})$.

Оговорка: для конечного measurement set, не содержащего все обучающие входы, objective — лишь *приближение* (не гарантированная граница для $\log p(\mathcal{D})$); функциональный KL может быть даже бесконечным.

Градиент KL, когда у q нет плотности

Likelihood-член вычислим, а плотность $q_\phi(\mathbf{f}^{\mathbf{X}})$ — нет. По репараметризации $f = g_\phi(\mathbf{x}, \xi)$:

$$\nabla_\phi \mathrm{KL}[q_\phi(\mathbf{f}^{\mathbf{X}}) \| p(\mathbf{f}^{\mathbf{X}})] = \underbrace{\mathbb{E}_q[\nabla_\phi \log q_\phi(\mathbf{f}^{\mathbf{X}})]}_{=0} + \mathbb{E}_\xi \left[\nabla_\phi \mathbf{f}^{\mathbf{X}} \left(\nabla_{\mathbf{f}} \log q(\mathbf{f}^{\mathbf{X}}) - \nabla_{\mathbf{f}} \log p(\mathbf{f}^{\mathbf{X}}) \right) \right].$$

Произведение якобиана на вектор считается backprop-ом; остаётся оценить score-функции $\nabla_{\mathbf{f}} \log q$ и $\nabla_{\mathbf{f}} \log p$.

Spectral Stein gradient estimator (SSGE)

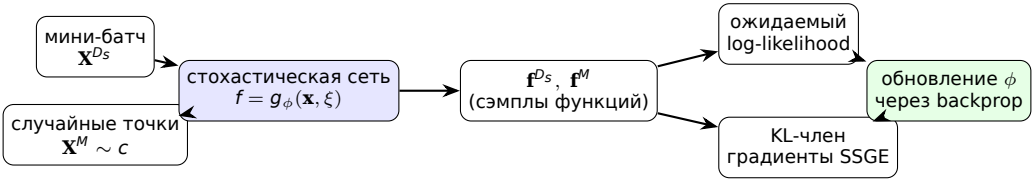
Оценивает $\nabla \log q(\mathbf{x})$ *implicit* распределения только по сэмплам:

$$\nabla_{x_i} \log q(\mathbf{x}) = -\sum_{j=1}^{\infty} \left[\mathbb{E}_q \nabla_{x_i} \psi_j(\mathbf{x}) \right] \psi_j(\mathbf{x}),$$

ψ_j: собственные функции ядра k (Mercer), приближаются методом Nyström; сумма обрезается, $\mathbb{E}_q$ заменяется оценкой Monte Carlo.

SSGE применяется для $\nabla \log q$ всегда и для $\nabla \log p$, когда prior implicit; для GP-prior $\nabla \log p$ считается точно (с шумом $K + \gamma^2 I$ для устойчивости).

Собираем всё вместе: как обучается fBNN



Objective, максимизируемый на каждой итерации:

$$\frac{1}{|\mathcal{D}_S|} \sum_{(\mathbf{x},y)\in\mathcal{D}_S} \mathbb{E}_{q_\phi} \log p(y \mid f(\mathbf{x})) \;-\; \lambda\, \mathrm{KL}\big[q(\mathbf{f}^{\mathcal{D}_S}, \mathbf{f}^{M}) \,\|\, p(\mathbf{f}^{\mathcal{D}_S}, \mathbf{f}^{M})\big].$$

- В принципе $\lambda = 1/|\mathcal{D}|$; так как KL по малому числу точек — лишь нижняя оценка функционального KL, большее λ помогает против переобучения. На практике $\lambda = 1/|\mathcal{D}_S|$ (тогда по теореме 2 это честная нижняя граница $\log p(\mathcal{D}_S)$).
- q во всех экспериментах: независимые гауссовы веса $\mathcal{N}(\boldsymbol{\mu}, \operatorname{diag}\boldsymbol{\sigma}^2)$; гиперпараметры GP сначала подбираются, затем фиксируются.

Может ли сеть экстраполировать по структуре prior

Периодическая структура (GP-prior)

- 20 точек из $[-2, -0.5] \cup [0.5, 2]$, $y = 2\sin(4x) + \varepsilon$
- BNN: 5 скрытых слоёв $\times$ 500 нейронов
- prior-ы: ядра RBF и PER+RBF
- measurement set: все обучающие точки + 40 случайных из $[-5, 5]$

Результат: fBNN $\approx$ точный GP с тем же ядром (чуть меньшая неопределённость). BBB не может даже подогнать обучающие данные.

Implicit prior-ы

- кусочно-постоянные и кусочно-линейные функции
- 40 точек из $[0, 0.2] \cup [0.8, 1]$; сеть с *tanh*, 2×100

Результат: сэмплы из posterior имеют резкие, примерно кусочные структуры, несмотря на tanh, но не отражают всё разнообразие объяснений.

Toy-пример $y = x^3$: предсказания fBNN согласованы при росте сети; предсказания BBB резко меняются.

Вывод

Экстраполяция следует из *functional prior*, а не из архитектуры (ReLU-сети не кодируют периодичность).

Сравнение с BBB и Noisy K-FAC на регрессии (test RMSE)

Малые датасеты UCI (GP-prior с подобранными гиперпараметрами; split 90/10, 10 повторов)

Датасет	BBB	Noisy K-FAC	fBNN
Boston	3.171 ± 0.149	2.742 ± 0.125	$\mathbf{2.378} \pm 0.104$
Concrete	5.678 ± 0.087	5.019 ± 0.127	$\mathbf{4.935} \pm 0.180$
Energy	0.565 ± 0.018	0.485 ± 0.023	$\mathbf{0.412} \pm 0.017$
Wine	0.643 ± 0.012	$\mathbf{0.637} \pm 0.011$	0.673 ± 0.014
Yacht	1.174 ± 0.086	0.979 ± 0.077	$\mathbf{0.607} \pm 0.068$

Большие датасеты (1 скрытый слой, 100 нейронов; GP-prior с NKN-ядрами; 5 запусков)

Датасет	N	BBB	fBNN
Naval	11 934	1.6E-4	**1.2E-4**
Protein	45 730	4.331	**4.326**
Video Memory	68 784	1.879	**1.858**
Video Time	68 784	3.632	**3.007**
GPU	241 600	21.886	**19.50**

Bandits и Bayesian optimization: зачем нужна неопределённость

Contextual bandits (Riquelme et al., 2018), Thompson sampling, prior = multi-task GP. Относительный накопленный regret (Uniform $= 100$), 6 датасетов, 10 запусков:

Метод	Mean rank ↓	Mean value ↓
fBNN 1×50	4.7	41.9
fBNN 1×500	**3.8**	41.3
fBNN 3×500	4.2	**40.9**
MultitaskGP	4.3	41.7
Dropout	5.5	41.7
BBB 1×50	10.8	52.7
BBB 1×500	13.7	66.2
Uniform	16	100

- fBNN стабилен при более глубоких и широких сетях; у BBB качество падает при переходе от 50 к 500 нейронам.
- Bayesian optimization (Max-value Entropy Search): fBNN даёт явные сэмплы функций; сопоставим с RBF random features на RBF-функциях и лучше на ArcCosine и Matern12.

Что получилось и где слабые места

Выводы

- KL между процессами = supremum конечных маргинальных KL
- fELBO, sampling-based measurement sets и SSGE дают практичную схему обучения
- prior-ы над функциями (GP, implicit) $\Rightarrow$ осмысленная экстраполяция, надёжная неопределённость, устойчивость к размеру сети
- конкурентно на UCI-регрессии, сильный результат на bandits

Ограничения

- конечные measurement sets: лишь приближение, λ подбирается эвристически
- сэмплы posterior для implicit prior-ов недостаточно разнообразны
- гиперпараметры GP подбираются заранее и фиксируются
- q по-прежнему факторизованная гауссиана по весам; масштабируемость SSGE в больших размерностях не исследована

Литература

[1] Sun S., Zhang G., Shi J., Grosse R. *Functional variational Bayesian neural networks.* ICLR 2019, arXiv:1903.05779.

[2] Blundell C., Cornebise J., Kavukcuoglu K., Wierstra D. *Weight uncertainty in neural network.* ICML 2015.

[3] Shi J., Sun S., Zhu J. *A spectral approach to gradient estimation for implicit distributions.* ICML 2018.

[4] Neal R. M. *Bayesian Learning for Neural Networks.* PhD thesis, University of Toronto, 1995.

[5] Rasmussen C. E., Williams C. K. I. *Gaussian Processes for Machine Learning.* MIT Press, 2006.

[6] Zhang G., Sun S., Duvenaud D., Grosse R. *Noisy natural gradient as variational inference.* ICML 2018.

[7] Riquelme C., Tucker G., Snoek J. *Deep Bayesian bandits showdown.* ICLR 2018.

[8] Matthews A. G. de G., Hensman J., Turner R., Ghahramani Z. *On sparse variational methods and the KL divergence between stochastic processes.* AISTATS 2016.

[9] Hafner D. et al. *Reliable uncertainty estimates in deep neural networks using noise contrastive priors.* arXiv:1807.09289, 2018.

[10] Hernández-Lobato J. M., Adams R. *Probabilistic backpropagation for scalable learning of Bayesian neural networks.* ICML 2015.

Два вопроса к аудитории

1. Почему задание prior над функциями (а не над весами) делает предсказания fBNN стабильными при росте сети?
2. Зачем в measurement set входят случайные точки из всей области определения, а не только обучающие входы?

Спасибо за внимание!