

Mixture of AI Experts

И. М. Латыпов

Кафедра Интеллектуальных систем МФТИ

2024


Мотивация: Модель смеси экспертов набирает популярность. И сейчас очень много работ, в которых исследуются различные аспекты моделей со смесями экспертов. Однако почти во всех из них рассматривается только небольшое число экспертов. Что будет, если использовать большое число экспертов?

Статья [1]

План:

1. Что такое смесь экспертов?
2. Million Experts.
3. Теоретическое предпосылки.

Смесь экспертов



Идея: все токены в модели после attention слоя проходя через одну большую матрицу. Это вычислительно дорого. Вместо этого сделаем активируемые слои. Токены распределяются при помощи routing метода.

Рисунок: <https://habr.com/ru/articles/879494/>

PEER layer:

1. Набор из N экспертов e_i с сигнатурой $f(x)$.
2. Каждому эксперту задан ключ $e_i \rightarrow k_i$.
3. Задана query function $q : \mathbb{R}^n \rightarrow \mathbb{R}^d$

Как считается выход:

$$g_i(x) = s(q(x)^T k_i)$$

$$f(x) = \sum_{i \in \text{TopK}(x)} g_i(x) e_i(x)$$

$$\text{TopK}(x) = \text{TopK}(\{q(x)^T k_i\}_i)$$

- время сопоставления одного токена $\propto Nd$ числу экспертов.

PEER: схема




Рис.: Схема работы PEER слоя. Фото в цвете.

PEER: решение проблемы

- ▶ Использовать product keys [2] в качестве роутера, и уменьшить время поиска до $O((\sqrt{N} + k^2)d)$.

Вместо набора ключей $\{k_i\}_{i \in \overline{1, N}}$ зададим два набора ключей $\mathbb{C} = \{c_i \in \mathbb{R}^{\frac{d}{2}}\}_{i \in \overline{1, \sqrt{N}}}$ и $\mathbb{C}'$.

Новый набор ключей определяется так:

$$\mathbb{K} = \left\{ \begin{bmatrix} c \\ c' \end{bmatrix} \mid c \in \mathbb{C}, c' \in \mathbb{C}' \right\}.$$

Поиск ТорК ключей:

1. Находим ТорК ключей по $\mathbb{C}'$ и $\mathbb{C}$. Обозначим их соответственно $\mathbb{I}_{\mathbb{C}}, \mathbb{I}_{\mathbb{C}'}$. Каждая по $\sqrt{N}$ объектов.
2. Находим ТорК среди ключей в произведении множеств:

$$\mathbb{K}' := \left\{ \begin{bmatrix} c_i \\ c_j \end{bmatrix} \mid i \in \mathbb{I}_{\mathbb{C}}, j \in \mathbb{I}'_{\mathbb{C}} \right\}. \text{ Их здесь } |\mathbb{K}'| = k^2$$

Определение экспертов:

$$e_i(x) = \sigma(u_i^T x) v_i \quad (1)$$

Трюк: multi head retrieval. Используют h штук разных retrieval сеток. Ablation study показывает, что это дает прирост к производительности.

Интересный факт: если брать $k = 1$, то полученная модель равносильна слою с активлируемыми нейронами.

$$f(x) = \sum_{i=1}^h e^i(x) = \sum_{i=1}^h \sigma(u_i^T x) v_i = V \sigma(W^T x); \quad (2)$$

Теоретические предпосылки

Зачем увеличивать число экспертов? Согласно [3] лосс МоЕ моделей аппроксимируется как:

$$\mathcal{L}(P, D, G) = c + \left(\frac{g}{G^\gamma} + a \right) \frac{1}{P^\alpha} + \frac{b}{D^\beta}$$
$$G = \frac{P_{\text{active}}}{P_{\text{expert}}}$$

1. D – number of training tokens
2. G – granularity
3. P – total number of parameters

Чтобы улучшить качество, необходимо увеличивать G, P, D . С другой стороны, нужно ограничить P_{active} , чтобы быстро все работало. Выразим $P_{\text{expert}} = P_{\text{active}}/G$,
 $N = P/P_{\text{expert}} = P \cdot G/P_{\text{active}}$.

- Нужно уменьшать размеры экспертов и увеличивать их количество.

Experiments


Вычисления: авторы использовали isoFLOP analysis. В нем задается количество вычислительных ресурсов на каждую модель, и все модели тренируются с использованием этого бюджета.

Конкуренты: Dense, MoE, PKM. Брали Dense модель, и заменяли её FFN слой на MoE, PKM или PEER слой. В MoE в качестве gating использовали expert choice [4]


Table 1: Perplexities of the compute-optimal models of each method on language modeling datasets.

Method	Curation Corpus	Lambada	Pile	Wikitext	C4
Dense (6e18)	23.26	21.95	24.55	29.14	23.84
MoE (6e18)	20.98	19.09	23.26	26.10	21.41
PKM (6e18)	21.80	19.39	20.49	27.09	21.92
PEER (6e18)	20.68	17.65	19.01	25.48	20.63
Dense (2e19)	17.70	12.28	18.19	21.21	18.31
MoE (2e19)	16.88	12.97	17.41	20.28	17.12
PKM (2e19)	17.03	11.18	16.34	20.26	17.36
PEER (2e19)	16.34	10.33	14.99	19.09	16.45

Experiments




(a) 6e18 FLOPs




(b) 2e19 FLOPs

Рис.: Isoflop comparison on the C4 dataset between PEER and other baselines with two different FLOP budgets (6e18 and 2e19 FLOPs). The x axis is in log scale.

Experiments: ablation



(a) Varying Total Expert Num



(b) Varying Active Expert Num

Рис.: Conducted two ablation studies using the same PEER model configuration. In (a), the total number of experts N varied while keeping the same number of active experts $hk = 128$. In (b), the number of active experts $G = hk$ varied by jointly changing h and k while keeping the total number of experts at $N = 1024^2$

Experiments: ablation




Рис.: Query BatchNorm Ablation. IsoFLOP curves of a PEER model with 1M experts on the C4 dataset, with and without query BatchNorm.

Experiment: active experts

Expert num N BatchNorm	16k		65k		262k		1M	
	No	Yes	No	Yes	No	Yes	No	Yes
Perplexity	23.47	23.47	22.61	22.55	21.54	21.47	20.73	20.64
Expert Usage (%)	100.0	100.0	100.0	100.0	100.0	100.0	99.8	100.0
Unevenness ($\downarrow$)	0.45	0.30	0.63	0.44	0.97	0.66	1.52	1.06

Рис.: KL and expert usage for different memory sizes, with and without query BN. Similar to the findings in PKM, using query BN results in a more balanced usage of the experts.

Summary

1. Посмотрели на МоЕ.
2. Поняли как сделать много экспертов.
3. Поняли, что эксперты работают, несмотря на то что их много.

- [1] Xu Owen He. “Mixture of a million experts”. B: *arXiv preprint arXiv:2407.04153* (2024).
- [2] Guillaume Lample и др. “Large memory layers with product keys”. B: *Advances in Neural Information Processing Systems* 32 (2019).
- [3] Jakub Krajewski и др. “Scaling laws for fine-grained mixture of experts”. B: *arXiv preprint arXiv:2402.07871* (2024).
- [4] Yanqi Zhou и др. “Mixture-of-experts with expert choice routing”. B: *Advances in Neural Information Processing Systems* 35 (2022), с. 7103—7114.