

Hyena Hierarchy: Towards Larger Convolutional Language Models

Крейнин Матвей

Московский физико-технический институт
Кафедра интеллектуальных систем

Постановка задачи

Дан вход $x \in \mathbb{R}^{L \times d}$ - последовательность длиной L , скрытое пространство d .

Требуется вычислить представление $y = f(x)$, которое сможет улавливать все зависимости, и ещё хорошо, если работает за:

$$\text{cost}_{time}, \text{cost}_{mem} \ll \mathbb{O}(L^2 d)$$

Attention:

$$A(x) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right), y = A(x)V$$

Матрица $A \in \mathbb{R}^{L \times L}$ - время и память $\mathbb{O}(L^2)$.

При $L = 64000$, Flash-Attention > 40 gb для $d = 512$.

Что хотим от Hyena:

- Субквадратичная сложность $\mathcal{O}(L \log L)$
- Неограниченный контекст
- Параметры не зависят от L .
- Хотим как у Attention, чтобы веса зависели от самого входа.

Оператор Нуена

- Свертка S_h : $(S_h x)_t = \sum_{k=0}^{L-1} h_k x_{t-k}$

- Гейтинг D_g : $(D_g x)_t = g_t \odot x_t$ - обе операции линейный

Оператор Нуена:

$$y = D_{x_N} S_{h_N} \dots D_{x_2} S_{h_2} D_{x_1} S_{h_1} x$$

- $h_{i'}$ – это фильтр длины L

- $x_{i'}$ – гейт, вычисляемый из промежуточного значения

Параметризация фильтров:

$$h_i[t] = w(t)(FFN(PE(t))), w(t) = \exp(-\alpha t)$$

- $w(t)$ – окно для затухания памяти

- $PE(t)$ – RoPE

- $FFN(x) = W_2 \sigma(W_1 x + b_1) + b_2$ – feed-forward

Оператор Hyena

Если будем делать 1-D Conv: $\mathbb{O}(L^2)$

FFT: $S_h(x) = \mathcal{F}^{-1}(\mathcal{F}(h) \odot \mathcal{F}(x)) \rightarrow$, вычисляем спектры $\mathcal{F}(h)$ и $\mathcal{F}(x)$, после перемножения выполняем обратное преобразование. Что требует $\mathbb{O}(L \log L)$ операций.

Каждый уровень удваивает эффективное окно: $R_1 = |h_1|$.

После N уровней будет экспоненциальный охват $R_N \sim 2^{N-1} R_1$.

Трудоемкость: $C_{FFT}(L) = c \cdot L \log L$ Hyena:

$$T_{Hyena} = N \cdot C_{FFT}(L) = \mathbb{O}(NL \log L), M_{Hyena} = \mathbb{O}(NL)$$

Attention:

$$T_{Attention} = \mathbb{O}(L^2 d), M_{Attention} = \mathbb{O}(L^2)$$

Псевдо-Код

```
def hyena_block(x, filters, ffns):  
    for h, ffn in zip(filters, ffns):  
        # 1) длинная свёртка  
        u = fftconv(x, h)          #  $O(L \log L)$   
        # 2) гейтинг  
        g = torch.sigmoid(ffn(x))  # dimension-wise  
        x = g * u  
    return x
```

Результаты

Table 4.3: Perplexity on WIKITEXT103 (same tokenizer). * are results from (Dao et al., 2022c). Deeper and thinner models (Hyena-slim) achieve lower perplexity.

Model	PERPLEXITY
Transformer (125M)	18.6
Hybrid H3 (125M)	18.5*
Performer (125M)	26.8*
Reformer (125M)	25.6*
AFT-conv (125M)	28.2
Linear Attention (125M)	25.6*
Hyena-3 (125M)	18.6
Hyena-3-slim (125M)	18.5

Table 4.7: Image classification top-1 accuracy.

Model	PATCH SIZE	SEQ LEN	DATASET	ACC (%)
ViT (87M)	16x16	196	ImageNet-1k	78.5
Hyena-ViT (88M)	16x16	196	ImageNet-1k	78.5
ViT (87M)	8x8	1024	ImageNet-1k	80.0
Hyena-ViT (88M)	8x8	1024	ImageNet-1k	79.8
S4ND-ISO (268k)	-	-	CIFAR-10	89.9
Hyena-ISO (202k)	-	-	CIFAR-10	91.2