

State Space Methods for Efficient Inference in Student-t Process Regression

Arno Solin, Simo Särkkä

2026

Постановка задачи

Цель

Разработать вычислительно эффективный метод регрессии, устойчивый к выбросам в данных.

Проблема

Гауссовские процессы (GP) — популярный инструмент регрессии, но имеют два ключевых недостатка:

- ▶ **Вычислительная сложность:** наивная GP-регрессия требует $O(n^3)$ операций из-за инверсии матрицы K^{-1} .
- ▶ **Неустойчивость к выбросам:** предсказательная дисперсия не зависит от значений наблюдений:

$$V_{\text{GP}}[f(x_*)] = k(x_*, x_*) - k_*^T K^{-1} k_*$$

Цель работы

Предложить алгоритм на основе процессов Стюдента- t (TP) со сложностью $O(n)$, сохраняющий аналитическое решение и обеспечивающий устойчивость к выбросам.

Гауссовский процесс

Определение

Процесс $f(x) \sim \mathcal{GP}(\mu(x), k(x, x'))$, если для любой конечной выборки:

$$(f(x_1), \dots, f(x_n))^T \sim \mathcal{N}(\mu, K), \quad K_{ij} = k(x_i, x_j)$$

GP-регрессия: предсказание

$$E_{\text{GP}}[f(x_*)] = k_*^T K^{-1} y$$

$$V_{\text{GP}}[f(x_*)] = k(x_*, x_*) - k_*^T K^{-1} k_*$$

Ключевое ограничение

Проблема GP

Дисперсия V_{GP} зависит **только от входных точек** x_i , но не от значений наблюдений y_i . При наличии выбросов неопределённость **не увеличивается**.

Распределение Стьюдента- t

Определение 2.1. Случайная переменная $y \in \mathbb{R}^n$ имеет многомерное распределение Стьюдента- t , $y \sim \text{MVT}(\mu, K, \nu)$, если:

$$p(y|\mu, K, \nu) = \frac{\Gamma\left(\frac{\nu+n}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right)((\nu-2)\pi)^{n/2} |K|^{1/2}} \left(1 + \frac{(y-\mu)^T K^{-1}(y-\mu)}{\nu-2}\right)^{-\frac{\nu+n}{2}}$$

При $\nu \rightarrow \infty$ получаем $\mathcal{N}(y|\mu, K)$.

Лемма 2.2 (смесь масштабов).

$$\gamma \sim \text{IG}\left(\frac{\nu}{2}, \frac{\nu-2}{2}\right), \quad y|\gamma \sim \mathcal{N}(\mu, \gamma K) \quad \implies \quad y \sim \text{MVT}(\mu, K, \nu)$$

Ключевая идея

Распределение Стьюдента- t = **гауссовское** с случайным масштабом γ .

Процесс Стьюдента- t (TP)

Определение 2.4. Процесс $f(x) \sim \text{TP}(\mu(x), k(x, x'), \nu)$, если для любой конечной выборки:

$$(f(x_1), \dots, f(x_n))^T \sim \text{MVT}(\mu, K, \nu)$$

Лемма 2.3 (условное распределение).

Для совместно t -распределённых векторов f_1, f_2 :

$$f_1 | f_2 \sim \text{MVT}(\mu_{1|2}, K_{1|2}, \nu_{1|2})$$

$$\mu_{1|2} = K_{12}K_{22}^{-1}(f_2 - \mu_2) + \mu_1$$

$$K_{1|2} = \frac{\nu - 2 + \beta}{\nu - 2 + n_2} \left(K_{11} - K_{12}K_{22}^{-1}K_{21} \right), \quad \beta = (f_2 - \mu_2)^T K_{22}^{-1} (f_2 - \mu_2)$$

$$\nu_{1|2} = \nu + n_2$$

Отличие от GP

Масштабирующий множитель $\frac{\nu - 2 + \beta}{\nu - 2 + n_2}$ зависит от наблюдений через β .

ТР-регрессия: переход к апостериорному распределению

Шаг 1 — Априорная модель и совместное распределение.

При $f \sim \text{TP}(0, k_\theta, \nu)$ по определению процесса:

$$\begin{pmatrix} f(x_*) \\ \mathbf{y} \end{pmatrix} \sim \text{MVT}\left(\mathbf{0}, \begin{pmatrix} k_\theta(x_*, x_*) & k_*^T \\ k_* & K \end{pmatrix}, \nu\right),$$

где $[K]_{ij} = k_\theta(x_i, x_j) + \sigma_n^2 \delta_{ij}$ и $[k_*]_i = k_\theta(x_*, x_i)$.

Шаг 2 — Применяем Лемму 2.3 (отождествление: $f_1 \leftrightarrow f(x_*)$, $f_2 \leftrightarrow \mathbf{y}$):

$$f(x_*) \mid D \sim \text{MVT}\left(\underbrace{k_*^T K^{-1} \mathbf{y}}_{\mu_{1|2}}, \underbrace{\frac{\nu - 2 + \beta}{\nu - 2 + n} (k_\theta(x_*, x_*) - k_*^T K^{-1} k_*)}_{K_{1|2}}, \underbrace{\nu + n}_{\nu_{1|2}}\right),$$

где $\beta = \mathbf{y}^T K^{-1} \mathbf{y}$.

Ключевое отличие от GP-регрессии

GP: $\mathbb{V}[f(x_*) \mid \mathbf{y}] = k_\theta(x_*, x_*) - k_*^T K^{-1} k_*$ (не зависит от $\mathbf{y}$)

ТР: $\mathbb{V}[f(x_*) \mid \mathbf{y}] = \frac{\nu - 2 + \beta}{\nu - 2 + n} (k_\theta(x_*, x_*) - k_*^T K^{-1} k_*)$ (растёт при выбросах)

Отрицательное логарифмическое маргинальное правдоподобие:

$$\mathcal{L}(\theta) = \frac{n}{2} \log((\nu-2)\pi) + \frac{1}{2} \log |K| - \log \Gamma\left(\frac{\nu+n}{2}\right) + \log \Gamma\left(\frac{\nu}{2}\right) + \frac{\nu+n}{2} \log\left(1 + \frac{\beta}{\nu-2}\right)$$

где $\beta = (y - \mu)^T K^{-1} (y - \mu)$.

Оцениваемые параметры:

- ▶ θ — гиперпараметры ковариационной функции k_θ
- ▶ σ_n^2 — уровень шума
- ▶ ν — степени свободы (тяжесть хвостов)

Связь GP с фильтром Калмана

Идея

Временной GP эквивалентен линейной динамической системе:

$$f(t) \sim \text{GP}(0, k(t, t')) \iff \text{СДУ пространства состояний}$$

Непрерывная форма (СДУ)

Начальное условие:

$$\mathbf{f}(0) \sim \mathcal{N}(0, P_\infty)$$

Уравнение состояния:

$$d\mathbf{f}(t) = F\mathbf{f}(t) dt + L dW(t)$$

Уравнение наблюдения:

$$y(t_k) = H\mathbf{f}(t_k) + \varepsilon_k$$

Дискретная форма

Начальное условие:

$$\mathbf{f}_0 \sim \mathcal{N}(0, P_\infty)$$

Переход состояния:

$$\mathbf{f}_k = A_{k-1}\mathbf{f}_{k-1} + \mathbf{q}_{k-1}$$

$$\mathbf{q}_{k-1} \sim \mathcal{N}(0, Q_{k-1})$$

Наблюдение:

$$y_k = H\mathbf{f}_k + \varepsilon_k$$

Главный результат: ТР как модель пространства состояний

Теорема 3.2

Временной ТР эквивалентен масштабированной смеси гауссовских СДУ:

$f(t) \sim \text{ТР}(0, k(t, t'), \nu) \iff$ гауссовская смесь СДУ пространства состояний

Непрерывная форма (СДУ)

Начальное условие:

$$\mathbf{f}(0) \sim \mathcal{N}(0, \gamma P_0)$$

Уравнение состояния:

$$d\mathbf{f}(t) = \mathbf{F}\mathbf{f}(t) dt + \mathbf{L} dW(t)$$

$$W(t) \sim \mathcal{N}(0, \gamma Q_c)$$

Уравнение наблюдения:

$$y(t_k) = \mathbf{H}\mathbf{f}(t_k) + \varepsilon_k$$

Дискретная форма

Начальное условие:

$$\mathbf{f}_0 \sim \mathcal{N}(0, \gamma P_0)$$

Переход состояния:

$$\mathbf{f}_k = \mathbf{A}_{k-1}\mathbf{f}_{k-1} + \mathbf{q}_{k-1}$$

$$\mathbf{q}_{k-1} \sim \mathcal{N}(0, \gamma Q_{k-1})$$

Наблюдение:

$$y_k = \mathbf{H}\mathbf{f}_k + \varepsilon_k$$

Алгоритм: фильтрация (вперёд)

Обозначения

$m_{k k}$	среднее
$P_{k k}$	ковариация
ν_k	степени св.
γ_k	масштаб
v_k	инновация
S_k	дисп. иннов.
K_k	усиление
$A_k(\theta)$	переход
$Q_k(\theta)$	шум перехода
$H_k(\theta)$	наблюдение

Инициализация

$$\begin{aligned} \nu_0 &= \nu & \gamma_0 &= 1 \\ m_{0|0} &= 0 & P_{0|0} &= P_0(\theta) \end{aligned}$$

Шаги для $k = 1, \dots, n$

1. Предсказание:

$$m_{k|k-1} = A_{k-1}(\theta) m_{k-1|k-1}$$

$$P_{k|k-1} = A_{k-1}(\theta) P_{k-1|k-1} A_{k-1}(\theta)^T + \gamma_{k-1} Q_{k-1}(\theta)$$

2. Инновация:

$$v_k = y_k - H_k(\theta) m_{k|k-1}, \quad S_k = H_k(\theta) P_{k|k-1} H_k(\theta)^T$$

3. Обновление масштаба:

$$\begin{aligned} \nu_k &= \nu_{k-1} + 1 \\ \gamma_k &= \frac{\nu_{k-1} - 2 + v_k^T S_k^{-1} v_k}{\nu_k - 2} \cdot \gamma_{k-1} \end{aligned}$$

4. Обновление состояния:

$$\begin{aligned} K_k &= P_{k|k-1} H_k(\theta)^T S_k^{-1} \\ m_{k|k} &= m_{k|k-1} + K_k v_k, \quad P_{k|k} = \frac{\gamma_k}{\gamma_{k-1}} (P_{k|k-1} - K_k S_k K_k^T) \end{aligned}$$

Алгоритм: сглаживание (назад)

Обозначения

$m_{k|n}$ сглаж. среднее

$P_{k|n}$ сглаж. ковар.

G_k коэфф. сглаж.

ν_n степени св.
(из фильтра)

D_k данные до t_k

D_n все данные

Инициализация

Из прямого прохода:

$m_{n|n}, P_{n|n}$

$\nu_n, \{\gamma_k\}_{k=0}^n$

Шаги для $k = n - 1, \dots, 0$

1. Предсказание:

$$m_{k+1|k} = A_k(\theta) m_{k|k}$$

$$P_{k+1|k} = A_k(\theta) P_{k|k} A_k(\theta)^T + \gamma_k Q_k(\theta)$$

2. Коэффициент сглаживания:

$$G_k = P_{k|k} A_k(\theta)^T P_{k+1|k}^{-1}$$

3. Обновление среднего:

$$m_{k|n} = m_{k|k} + G_k (m_{k+1|n} - m_{k+1|k})$$

4. Обновление ковариации:

$$P_{k|n} = \frac{\gamma_n}{\gamma_{k-1}} (P_{k|k} - G_k P_{k+1|k} G_k^T) + G_k P_{k+1|n} G_k^T$$

Маргинальное правдоподобие

Отрицательное лог-правдоподобие

$$\mathcal{L}(\theta) = \sum_{k=1}^n \left[\frac{1}{2} \log((\nu - 2)\pi) + \frac{1}{2} \log |S_k(\theta)| + \log \Gamma\left(\frac{\nu_{k-1}}{2}\right) - \log \Gamma\left(\frac{\nu_k}{2}\right) \right. \\ \left. + \frac{1}{2} \frac{\log(\nu_k - 1 - 2)}{\nu - 2} + \frac{\nu_k}{2} \log \left(1 + \frac{v_k(\theta)^T S_k(\theta)^{-1} v_k(\theta)}{\nu_{k-1} - 2} \right) \right]$$

Обновление и вычислительная выгода

Обновление происходит после каждой итерации алгоритма фильтрации, оно происходит до сходимости. При $m \ll n$: $O(nm^3) \approx O(n)$ против $O(n^3)$ для наивного решения.

Эксперимент 1




Рис.: Демонстрация вычислительной эффективности наивного алгоритма и алгоритма через фильтр Калмана

Эксперимент 2

Данные

- **Synth A:** наблюдения порождены добавлением *независимого* гауссовского шума $\varepsilon_j \sim \mathcal{N}(0, \sigma_n^2)$.
- **Synth B:** наблюдения порождены добавлением *независимым* Student-*t* шумом с параметром степеней свободы ν .
- **Synth C:** смесь: для 75% точек $\varepsilon_j \sim \mathcal{N}(0, \sigma_n^2)$, для 25% — выбросы $\varepsilon_j \sim \mathcal{N}(0, 100\sigma_n^2)$.
- **Electricity:** почасовые усреднения потребления одного домохозяйства за 1442 дня.
- **Stock (Apple):** лог-цены акций Apple в течении 8537 дней.

DATA SET	NAIVE GP		STATE SPACE GP		NAIVE TP		STATE SPACE TP	
	MSE	LL	MSE	LL	MSE	LL	MSE	LL
SYNTH A	0.04 ± 0.02	-25 ± 4	0.04 ± 0.02	-25 ± 4	0.04 ± 0.02	-25 ± 4	0.04 ± 0.02	-25 ± 4
SYNTH B	0.15 ± 0.28	-36 ± 17	0.13 ± 0.17	-36 ± 17	0.12 ± 0.11	-36 ± 17	0.12 ± 0.11	-36 ± 17
SYNTH C	0.56 ± 0.85	-46 ± 7	0.56 ± 0.85	-46 ± 7	0.39 ± 0.23	-46 ± 7	0.38 ± 0.21	-46 ± 7
ELECTRICITY	—	—	0.64 ± 0.20	-3261 ± 241	—	—	0.56 ± 0.04	-3287 ± 101
STOCK	—	—	5.16 ± 15	-1700 ± 339	—	—	0.41 ± 0.84	-1701 ± 339

Рис.: GP и TP: сравнение наивной реализации и state-space метода. В таблице приведены усреднённые по реализациям MSE и лог-правдоподобие.

Сравнение методов и заключение

Свойство	Наивный GP	SS GP	Наивный TP	SS TP
Сложность	$O(n^3)$	$O(n)$	$O(n^3)$	$O(n)$
Выбросы	×	×	✓	✓
Адапт. дисперсия	×	×	✓	✓
Аналит. решение	✓	✓	✓	✓
Реальное время	×	✓	×	✓

Заключение

Метод SS TP объединяет все преимущества: линейную сложность $O(n)$ и устойчивость к выбросам.