

Score-Based VAMP with Fisher-Information-Based Onsager Correction

Обзор статьи: Wadayama & Takahashi (2026)

Минашкин В.М., МФТИ

Май 2026

Содержание

Введение

Мотивация

Немного математики

Алгоритм Score-VAMP

Результаты

От AMP к VAMP

- ▶ AMP (Approximate Message Passing) — итеративный алгоритм для линейных обратных задач
 - ▶ Состоит из линейного шага и нелинейного шумоподавления
 - ▶ Коррекция Онзагера убирает корреляции между итерациями
 - ▶ Асимптотическая динамика описывается State Evolution (SE)
- ▶ VAMP (Vector AMP) обобщает AMP на матрицы общего вида
 - ▶ Работает с право-инвариантными (RRI) матрицами измерений
 - ▶ Сходится даже тогда, когда AMP расходится
 - ▶ Использует SVD-разложение матрицы A

Структура классического VAMP

LMMSE модуль (Module A)

Обработывает линейные измерения $y = Ax + w$:

$$x_{1,t} = \text{LMMSE}(r_{1,t}, y), \quad \alpha_{1,t} = \frac{1}{N} \text{div}(\eta_{1,t})$$

Denoiser модуль (Module B)

Убирает шум, порождённый линейным шагом:

$$x_{2,t} = \eta_{2,t}(r_{2,t}), \quad \alpha_{2,t} = \frac{1}{N} \text{div}(\eta_{2,t})$$

- Основная проблема: вычисление дивергенции $\text{div}(\eta)$ для сложных денойзеров (нейросетей) требует $O(N^2)$ операций.

Задача восстановления сигнала

Рассматривается линейная обратная задача:

$$y = Ax_0 + w, \quad w \sim \mathcal{N}(0, \sigma_w^2 I)$$

Проблемы классического VAMP:

- ▶ Требуется вычисления дивергенции (следа Якобиана) денойзера $\eta_t(\cdot)$ на каждой итерации.
- ▶ Для глубоких нейросетей вычисление $\text{div}(\eta_t) = \sum \frac{\partial \eta_{t,i}}{\partial r_i}$ вычислительно дорого (или через Monte Carlo).

Решение: Использовать связь между Score-based моделями и теорией оценивания.

Формула Твиди и Score-функция

Пусть $r = x + \sqrt{\gamma^{-1}}z$ — зашумленное наблюдение. Оптимальный денойзер (MMSE) выражается через Score-функцию (градиент логарифма плотности):

Формула Твиди

$$\hat{x} = \mathbb{E}[x|r] = r + \frac{1}{\gamma} \nabla_r \log p(r; \gamma)$$

- ▶ $\nabla_r \log p(r)$ — это и есть Score-функция.
- ▶ В современных диффузионных моделях обучается нейросеть $s_\theta(r, \gamma) \approx \nabla_r \log p(r; \gamma)$.

Коррекция Онзагера через Информацию Фишера

Для сходимости VAMP необходим расчёт скалярного коэффициента $\alpha_t = \frac{1}{N} \text{div}(\eta_t(r_t))$.

Ключевой теоретический вклад: Авторы показывают, что:

$$\alpha_t = 1 - \frac{1}{\gamma_t} \text{mmse}(\gamma_t)$$

Где MMSE связано с ожидаемой **информацией Фишера** $J(\gamma)$:

$$J(\gamma) = \mathbb{E}_r \left[\|\nabla_r \log p(r; \gamma)\|^2 \right]$$

В итоге: теперь коррекцию можно считать через норму выхода нейросети, а не через её производные, что упрощает нам жизнь

Алгоритм Score-Based VAMP

1. LMMSE шаг: Обновление по линейным измерениям (как в обычном VAMP).
2. Denoising шаг:


$$\mathbf{x}_{1,t} = \mathbf{r}_{1,t} + \frac{1}{\gamma_{1,t}} \mathbf{s}_{\theta}(\mathbf{r}_{1,t}, \gamma_{1,t})$$

3. Jacobian-Free Onsager:

$$\alpha_{1,t} = \frac{1}{N\gamma_{1,t}} \sum_{i=1}^N \|\mathbf{s}_{\theta}(\mathbf{r}_{1,t}, \gamma_{1,t})\|_i^2$$


4. Обновление: $\mathbf{r}_{2,t} = (\mathbf{x}_{1,t} - \alpha_{1,t}\mathbf{r}_{1,t})/(1 - \alpha_{1,t})$

Эксперименты: MSE и сходимость



- ▶ SC-VAMP достигает той же точности, что и классический VAMP с точной дивергенцией
- ▶ При этом время одной итерации сокращается в 10–50 раз
- ▶ Метод работает с предобученными score-моделями без дообучения

State Evolution и теоретический предел



- ▶ Эмпирические траектории SC-VAMP следуют теоретическим кривым SE
- ▶ Это подтверждает несмещённость аппроксимации коррекции через норму score-функции
- ▶ В пределе больших размерностей достигается Bayes-optimal производительность

Заключение

- ▶ Уход от Якобианов ускоряет итерацию в десятки раз для больших сетей.
- ▶ Метод работает с любыми предобученными диффузионными моделями.
- ▶ Достигается теоретический предел Bayes-optimal при использовании точного Score.